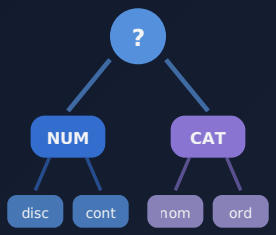

Tipos de Dados em Saúde

Da coleta à análise — entendendo variáveis para pesquisa em saúde.
De Stevens a Likert, do dicionário de variáveis à publicação dos dados.

Prof. Henrique Alvarenga da Silva

UFSJ · UNIPTAN/AFYA

Começar a explorar →

scroll ↓

PARTE I

Fundamentos

Os Dados da Pesquisa

O que são dados, quem os define, e por que a classificação correta é o primeiro passo de qualquer análise. De Florence Nightingale aos hospitais modernos.

Fundamentos →

Classificação dos Tipos de Dados

O mapa completo: numéricos vs. categóricos, discretos vs. contínuos, nominais vs. ordinais. De Stanley Stevens (1946) ao debate que dura até hoje.

Fundamentos →

Dicionário de Variáveis

Como documentar cada variável: nome, tipo, unidade, limites e níveis. A história do Mars Climate Orbiter — quando a falta de documentação custou US$ 125 milhões.

Fundamentos →

PARTE II

Tipos de Dados em Detalhe

Dados Numéricos

Discretos vs. contínuos, binários numéricos (0/1), por que não têm níveis mas têm limites. A história de Adolphe Quetelet e o "homem médio".

Tipos de Dados →

Dados Categóricos

Nominais vs. ordinais, o papel do pesquisador na definição dos níveis. A história de John Graunt e as Bills of Mortality de Londres (1662).

Tipos de Dados →

Casos Especiais

Quando o tipo muda: Likert (ordinal → numérica), idade em anos vs. faixa etária, peso em kg vs. "magro/gordo". A história de Rensis Likert e a escala que leva seu nome.

Casos Especiais →

PARTE III

Na Prática

Organizando Dados em Planilhas

Boas práticas para Excel e CSV. Tidy data na prática. O escândalo Reinhart–Rogoff: quando um erro de planilha influenciou políticas de países inteiros.

Na Prática →

Visualizando por Tipo de Dado

Qual gráfico usar para cada tipo de variável: scatter, boxplot e histograma para numéricos; barras e pizza para categóricos; linhas para séries temporais.

Na Prática →

Publicando seus Dados

Dados abertos, princípios FAIR, repositórios e reprodutibilidade. A crise de reprodutibilidade e por que Ioannidis disse que "a maioria dos achados é falsa".

Na Prática →

Os Dados da Pesquisa

O que são dados, quem os define, e por que classificá-los é o primeiro passo

Introdução

Hoje a classificação dos dados em pesquisa segue uma estrutura simples: **numéricos** ou **categóricos**. Dados numéricos (ou quantitativos) podem ser discretos — quando assumem valores inteiros, como número de internações — ou contínuos — quando admitem qualquer valor num intervalo, como peso ou pressão arterial. Dados categóricos (ou qualitativos) podem ser nominais — quando as categorias não têm ordem, como tipo sanguíneo ou cidade — ou ordinais — quando existe uma hierarquia entre os níveis, como estadiamento de câncer ou escala de dor. Um caso especial são as variáveis binárias, que têm exatamente dois níveis (sim/não, presente/ausente) e aparecem com enorme frequência em estudos de saúde.

Essa estrutura que hoje parece quase óbvia, um dia precisou ser inventada. E a razão pela qual foi inventada é que, sem ela, os dados viravam uma bagunça — as mesmas informações recebiam nomes diferentes, registros de fontes distintas não podiam ser comparados, e conclusões contraditórias surgiam dos mesmos fenômenos.

A história

Na Inglaterra da primeira metade do século XIX, as estatísticas de mortalidade eram uma bagunça. Cada doença podia ter três ou quatro nomes diferentes, e cada nome podia se referir a doenças diferentes. As complicações eram registradas no lugar das doenças primárias. Não havia padrão.

William Farr sabia disso melhor do que ninguém. Nomeado em 1839 como o primeiro estatístico do General Register Office da Inglaterra — o

órgão responsável pelos registros de nascimentos, casamentos e óbitos — Farr passou a receber, organizar e analisar os dados de mortalidade de todo o país. O problema ficou evidente já no primeiro relatório anual, onde ele escreveu:

> *"The advantages of a uniform nomenclature, however imperfect, are so obvious, that it is surprising no attention has been paid to its enforcement in Bills of Mortality. Each disease has, in many instances, been denoted by three or four terms, and each term has been applied to as many different diseases."*

E completou: a nomenclatura de doenças é tão importante para a estatística *"as weights and measures in the physical sciences, and should be settled without delay"* (1).

Farr não ficou na reclamação. Ao longo das quatro décadas seguintes, ele construiu uma classificação sistemática de doenças — dividida em epidêmicas, constitucionais, locais (organizadas por sítio anatômico), do desenvolvimento e por causas externas — que se tornaria a base da futura Classificação Internacional de Doenças, o CID (1,2).

Quinze anos depois, o mesmo problema apareceu de outra forma. Florence Nightingale voltou da Guerra da Crimeia em 1856 convencida de que os soldados britânicos estavam morrendo mais de doenças infecciosas do que de ferimentos de batalha — mas provar isso com os dados disponíveis era quase impossível. Ela comparou seis fontes oficiais diferentes de registros de mortalidade e nenhuma concordava com as outras. Os registros hospitalares capturavam apenas um sétimo das mortes reais. Soldados que eram admitidos e morriam entre as contagens semanais simplesmente não apareciam nos números (3).

Numa carta ao cientista militar John Henry Lefroy, Nightingale descreveu os dados do Land Transport Corps como estando em *"a state of great confusion"*, com *"an extraordinary method (or no method) of keeping statistics"*. Sobre a Índia, onde certas causas de morte eram convenientemente excluídas dos relatórios oficiais, ela foi mais ácida: *"I could not help laughing at your critics who 'exclude' specific diseases*

such as ‘cholera,’ accidents ‘proving fatal,’ etc. It is very convenient indeed to leave out all deaths that ought not to have happened” (3).

Nightingale não era estatística de formação, mas entendia que o problema era anterior à análise: antes de calcular qualquer proporção, era preciso decidir **o que** registrar e **como** registrar. Ao voltar para a Inglaterra, ela fez pressão política pela padronização dos dados hospitalares nas forças armadas — e recrutou Farr para resolver o lado técnico (1).

Foi essa padronização que tornou possíveis os seus célebres diagramas de área polar — os *coxcombs* — que mostraram ao Parlamento britânico, de forma visual e imediata, que a maioria dos soldados morria por condições sanitárias, não por combate. O gráfico era poderoso, mas só existiu porque os dados por trás dele haviam sido padronizados antes. Em 1858, Nightingale se tornou a primeira mulher eleita fellow da Royal Statistical Society (3).

> 💡 **A lição de Farr e Nightingale**
>
> Dados não existem prontos na natureza. Alguém precisa decidir **o que** observar, **como** medir e **de que forma** registrar. Essas decisões — que antecedem qualquer análise — são o tema deste livro.

O percurso deste livro

Este livro está organizado em três blocos.

O primeiro — **Fundamentos**. Neste capítulo vimos que dados não existem prontos: alguém precisa decidir o que medir e como registrar, e que essa decisão determina as análises possíveis. No capítulo seguinte, vamos conhecer a classificação formal dos tipos de dados — de onde veio, quem a inventou, que debates gerou — e chegar ao mapa que usaremos no restante do livro: numéricos (discretos e contínuos) e categóricos (nominais e ordinais). No terceiro capítulo, veremos como documentar essas decisões num dicionário de variáveis — o documento que garante que todos os envolvidos num estudo entendam cada coluna do banco de dados da mesma forma. A história do Mars Climate Orbiter,

que perdeu uma sonda de 125 milhões de dólares por falta de documentação sobre unidades de medida, mostra que isso não é formalismo.

O segundo bloco — **Tipos de Dados** — entra no detalhe de cada tipo. Um capítulo inteiro dedicado aos dados numéricos: o que muda entre discretos e contínuos, quais descritivas usar, o debate sobre escalas intervalar e de razão e por que ele ficou na teoria. Outro capítulo dedicado aos categóricos: nominais, ordinais, binários, tabelas de frequência, tabelas de contingência e o papel do pesquisador na definição dos níveis. E um terceiro capítulo sobre os casos que não se encaixam facilmente em nenhuma gaveta — a escala de Likert (ordinal ou numérica?), o IMC (contínuo que vira categórico) e outras variáveis que mudam de identidade dependendo do contexto.

O terceiro bloco — **Na Prática** — é onde a classificação encontra o mundo real. Como organizar dados em planilhas sem criar armadilhas para si mesmo. Qual gráfico usar para cada tipo de variável. Como publicar dados seguindo os princípios FAIR de ciência aberta. E, finalmente, como o R e o Python enxergam os tipos de dados — porque o software não lê a sua mente, e a forma como ele armazena uma variável nem sempre corresponde ao que você pretendia.

Referências

1. Moriyama IM, Loy RM, Robb-Smith AHT. History of the Statistical Classification of Diseases and Causes of Death. Rosenberg HM, Hoyert DL, editores. Hyattsville, MD: National Center for Health Statistics; 2011.
2. Halliday S. William Farr: Campaigning Statistician. Journal of Medical Biography. 2000;8(4):220–7.
3. Bradshaw NA. Florence Nightingale (1820–1910): An Unexpected Master of Data. Patterns. 2020;1(2):100036.

Classificação dos Tipos de Dados

Numéricos vs. Categóricos

Introdução

Classificar corretamente os dados de uma pesquisa é uma etapa fundamental da análise estatística, é o momento em que o pesquisador decide o que aquele número representa, determinando tudo o que vem depois. É a classificação que diz se faz sentido calcular uma média ou se o correto é contar frequências. É ela que separa o histograma do gráfico de barras, o teste t do qui-quadrado, a correlação de Pearson da de Spearman.

Parece simples e óbvio dizer que a altura medida em metros é uma variável numérica e que o sexo é uma variável categórica. É fácil esquecer que alguém precisou inventar essa classificação. A história da classificação das variáveis e suas reviravoltas vale a pena ser contada.

ⓘ **A história**

Em 1946, Stanley Smith Stevens publicou na revista *Science* um artigo de pouco mais de três páginas que mudaria para sempre a forma como cientistas pensam sobre medição. O título era direto: “On the Theory of Scales of Measurement”. A proposta, audaciosa: toda medição científica pode ser classificada em quatro escalas — **nominal, ordinal, intervalar e de razão** (1).

O artigo não surgiu do nada. Stevens respondeu a um impasse que durava quase uma década. Em 1932, a British Association for the Advancement of Science criou um comitê com representantes da psicologia e da física para responder a uma pergunta aparentemente simples: sensações psicológicas — como a percepção de intensidade sonora — podem ser “medidas”? Após oito anos de deliberações, psicólogos e físicos não conseguiram chegar a um acordo. Os físicos esperavam que toda medição obedecesse à adição; os psicólogos sabiam que suas escalas não se comportavam assim (1,2).

Stevens resolveu o impasse reformulando a própria definição de medição. Em vez de exigir propriedades aditivas, ele propôs que **“medição é a atribuição de**

numerais a objetos ou eventos segundo regras” (1). Diferentes regras geram diferentes escalas, e cada escala admite diferentes operações estatísticas. A Tabela 1 de seu artigo — reproduzida abaixo — tornou-se uma das mais citadas da história da estatística.

Tabela 1: As quatro escalas de Stevens (1946) — adaptada da Tabela 1 do artigo original.

Escala	Operação empírica básica	Estatísticas permissíveis	Exemplo em saúde
Nominal	Determinação de igualdade	Frequência, moda, correlação de contingência	Tipo sanguíneo (A, B, AB, O)
Ordinal	Determinação de maior ou menor	Mediana, percentis	Estadiamento de câncer (I, II, III, IV)
Intervalar	Determinação de igualdade de intervalos	Média, desvio-padrão, correlação de Pearson	Temperatura corporal em °C
Razão	Determinação de igualdade de razões	Média geométrica, coeficiente de variação	Peso em kg, altura em cm

A taxonomia de Stevens — conhecida pela sigla **NOIR** — foi rapidamente adotada por livros-texto de estatística nas ciências sociais e da saúde. De Siegel (1956) a Robinson (1960), o esquema oferecia algo irresistível: **uma regra simples para escolher o teste estatístico certo a partir do tipo de dado** (2,3).

A taxonomia NOIR dominou o ensino de estatística por quase meio século. Mas, ao longo desse período, acumulou críticas de peso. Velleman e Wilkinson, em um artigo provocativo de 1993 no *The American Statistician*, argumentaram que as tipologias de Stevens são **“enganosas”** (3). O problema central, segundo eles, é que o tipo de escala **não é um atributo fixo dos dados** — depende da pergunta que fazemos e da informação adicional que temos (3).

O debate sobre a taxonomia de Stevens dividiu estatísticos em dois campos ao longo de décadas. De um lado, teóricos da medição argumentam que o nível de escala deveria restringir a escolha do teste estatístico (**feuerstahler2023?**). Do outro, estatísticos aplicados como Tukey e Lord sempre defenderam que essa prescrição é rígida demais (3). Na prática, o lado aplicado prevaleceu: quase nenhum software estatístico moderno usa a taxonomia NOIR e a divisão operacional que se consolidou ficou mais simples: numérico vs. categórico (3,4).

O mapa completo

A árvore abaixo organiza os tipos de dados que você encontrará na maioria dos conjuntos de dados de pesquisa em saúde:

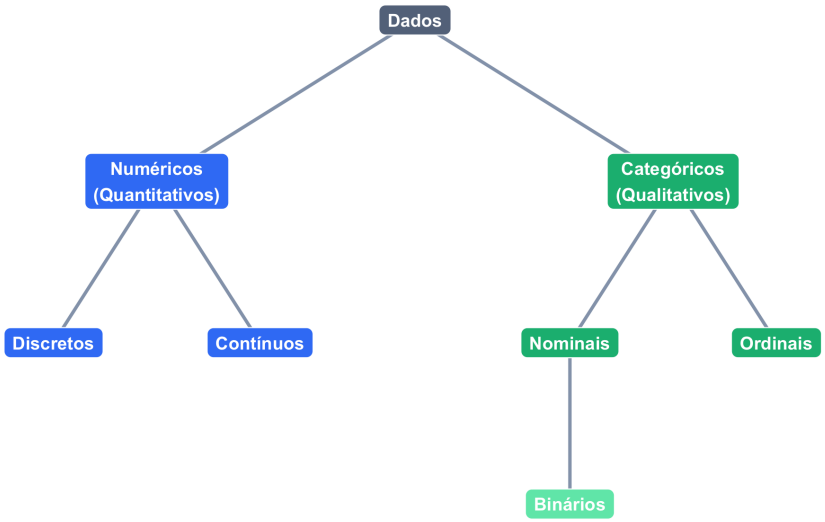

Figura 1: Árvore de classificação dos tipos de dados em pesquisa em saúde.

A distinção primária é entre **numéricos** (quantitativos) e **categóricos** (qualitativos). Dentro de cada ramo, subdivisões adicionais determinam como os dados se comportam — e quais análises são adequadas.

Numéricos (Quantitativos)

Dados numéricos representam **quantidades**. São valores sobre os quais operações aritméticas fazem sentido (soma, subtração, média, etc).

> ⓘ **E no computador?**
>
> Quando carregamos dados num software estatístico, ele precisa decidir como armazenar cada valor na memória. Para dados numéricos, a distinção mais importante é entre **números inteiros** (`int`, `integer`) e **números com casas decimais** (`float`, `double`, `numeric`) — o computador reserva espaços de memória diferentes para cada um. Essa diferença pode parecer um detalhe técnico, mas tem consequências práticas: um número de internações (que só

> pode ser 0, 1, 2, 3...) é armazenado de forma diferente de um peso corporal (que pode ser 72,3 kg). Veremos como o R e o Python lidam com isso no **Capítulo 10**.

Numéricos Discretos

Dados discretos assumem valores inteiros e não admitem frações no contexto em que são coletados. Não faz sentido dizer que um determinado paciente teve 2,7 internações ou que uma determinada família tem 1,3 filhos.

Exemplos em saúde: número de internações, número de consultas no último ano, quantidade de medicamentos em uso, número de dentes cariados.

Tabela 2: Exemplos de variáveis numéricas discretas em pesquisa em saúde.

Variável	Valores possíveis	Operação	Descritivas
Número de internações	0, 1, 2, 3, ...	Contagem	Mediana, média, DP
Quantidade de medicamentos	0, 1, 2, 3, ...	Contagem	Mediana, média, DP
Número de filhos	0, 1, 2, 3, ...	Contagem	Mediana, média, DP
Número de consultas/ano	0, 1, 2, 3, ...	Contagem	Mediana, média, DP

Numéricos Contínuos

Dados contínuos resultam de **medições**. Podem assumir qualquer valor dentro de um intervalo, incluindo frações arbitrariamente precisas. A precisão é limitada apenas pelo instrumento de medida, não pela natureza da variável.

Exemplos em saúde: peso (72,301 kg; 72,350 kg), altura (168,5 cm), pressão arterial (118 mmHg), colesterol (203 mg/dL), temperatura corporal (36,7 °C).

No nosso banco de dados, as variáveis contínuas predominam:

Tabela 3: Variáveis numéricas contínuas do estudo — note a amplitude e a precisão decimal.

Variável	Unidade	Amplitude (mín – máx)	Média
idade	anos	19 – 92	46.9
colesterol	mg/dL	78 – 443	207.8
glicose	mg/dL	48 – 385	106.7
hdl	mg/dL	12 – 120	50.4
peso	kg	44.91 – 147.42	80.6
altura	cm	132.08 – 193.04	167.7
sistolica	mmHg	90 – 250	136.9
diastolica	mmHg	48 – 124	83.3

A distinção entre discreto e contínuo pode parecer sutil, mas tem consequências práticas. Variáveis contínuas admitem distribuições de probabilidade contínuas (como a normal); variáveis discretas seguem distribuições discretas (como a Poisson ou a binomial). Essa diferença se reflete na escolha de modelos estatísticos.

Categóricos (Qualitativos)

Dados categóricos representam **categorias** ou **rótulos**. Os valores indicam a qual grupo o sujeito pertence, mas não representam medições.

> ⓘ **E no computador?**
>
> No R, variáveis categóricas são armazenadas como `factor` — um tipo que permite definir quais são os níveis válidos e se existe uma ordem entre eles (nominal ou ordinal). No Python (pandas), o equivalente é o tipo `category`. Veremos como usar ambos no **Capítulo 10**.

categóricos Nominais

Dados nominais classificam sujeitos em categorias **sem qualquer relação de ordem**. Não existe hierarquia entre os níveis — reorganizá-los em qualquer sequência não altera o significado.

Exemplos em saúde: tipo sanguíneo (A, B, AB, O), sexo (feminino, masculino), cidade de residência, cor dos olhos, estado civil.

Tabela 4: Variáveis categóricas nominais do estudo.

Variável	Nível	n	%
sexo	female	234	58.1
sexo	male	169	41.9
cidade	Buckingham	200	49.6
cidade	Louisa	203	50.4

Um caso particular dos nominais são os **binários** — variáveis com exatamente dois níveis. A variável sexo no nosso estudo é um exemplo. Variáveis binárias são extremamente comuns em saúde: diagnóstico (presente/ausente), desfecho (óbito/alta), exposição (sim/não). Conceitualmente, são variáveis categóricas — representam grupos, não quantidades (4). Mas a codificação numérica 0/1, tão habitual na prática, abre uma porta interessante: a média de uma variável codificada como 0 e 1 é a proporção de “1” no grupo — uma operação aritmética perfeitamente legítima sobre algo que, em essência, é categórico. Na prática, a classificação depende do que se faz com a variável: quando entra como desfecho em uma regressão logística, é tratada como categórica; quando entra como preditora codificada 0/1 em uma regressão linear, opera como numérica. É mais um exemplo de que a fronteira entre tipos de dados nem sempre é uma linha nítida — tema que retomaremos no capítulo sobre casos especiais.

Categóricos Ordinais

Dados ordinais classificam sujeitos em categorias **com uma ordem implícita**, mas cujas distâncias entre os níveis não são necessariamente iguais. Sabemos que “grau III” é mais grave que “grau II”, mas não podemos afirmar que a diferença entre I e II é a mesma que entre II e III.

Exemplos em saúde: estadiamento de câncer (I < II < III < IV), classe funcional da insuficiência cardíaca (NYHA I–IV), grau de obesidade, escala de dor (leve < moderada < intensa), classificação ASA de risco cirúrgico.

No nosso estudo, a variável `biotipo` é ordinal — seus níveis seguem uma ordenação de tamanho corporal:

Tabela 5: Distribuição do biotipo — uma variável categórica ordinal.

Biotipo (ordenado)	n	%
small	104	26.6
medium	184	47.1
large	103	26.3

A distinção entre nominal e ordinal é crucial: para dados ordinais, podemos calcular a mediana (o nível central), mas a média não faz sentido — pois exigiria distâncias iguais entre os níveis.

> ⚠ **O perigo da falsa precisão**
>
> Tratar uma variável ordinal como numérica — por exemplo, atribuir 1, 2, 3, 4 aos graus de obesidade e calcular a média — é um erro frequente. A média de 2,3 graus de obesidade **não tem significado clínico**. Esse é um dos pontos que exploraremos em profundidade no Capítulo 6, ao discutir a escala de Likert.

Tabela-resumo

A tabela abaixo sintetiza toda a classificação, com as características que distinguem cada tipo de dado e suas implicações para a análise:

Tabela 6: Resumo da classificação dos tipos de dados em pesquisa em saúde.

Tipo	Definição	Exemplo	Medida de centro	Medida de dispersão	Gráfico	Teste
Numérico discreto	Resultado de contagem; valores inteiros	Nº de internações, nº de filhos	Média ou mediana	DP, amplitude	Histograma, boxplot	t, ANOVA, Wilcoxon
Numérico contínuo	Resultado de medição; qualquer valor em um intervalo	Peso (kg), colesterol (mg/dL), altura (cm)	Média ou mediana	DP, amplitude, IIQ	Histograma, boxplot	t, ANOVA, correlação

Tipo	Definição	Exemplo	Medida de centro	Medida de dispersão	Gráfico	Teste
Categórico nominal	Categorias sem ordem; rótulos intercambiáveis	Sexo, tipo sanguíneo, cidade	Moda	—	Barras, setores	Qui-quadrado, Fisher
Categórico ordinal	Categorias com hierarquia; ordem, mas sem distâncias iguais	Estadiamento de câncer, biotipo, escala de dor	Mediana	IIQ	Barras (ordenadas)	Mann-Whitney, Kruskal-Wallis

Próximos passos

- **Capítulo 3** — Como documentar essa classificação em um dicionário de variáveis
- **Capítulo 4** — Dados numéricos em profundidade (discretos, contínuos, escalas de medida)
- **Capítulo 5** — Dados categóricos em profundidade (níveis definidos pelo pesquisador, recodificação)
- **Capítulo 6** — Casos especiais: quando a classificação não é óbvia (Likert, idade, IMC)

Referências

1. Stevens SS. On the Theory of Scales of Measurement. Science. 1946;103(2684):677–80.
2. Chrisman NR. Rethinking Levels of Measurement for Cartography. Cartography and Geographic Information Science. 1998;25(4):231–42.
3. Velleman PF, Wilkinson L. Nominal, Ordinal, Interval, and Ratio Typologies Are Misleading. The American Statistician. 1993;47(1):65–72.
4. Agresti A. Statistical Methods for the Social Sciences. 5.ª ed. Boston: Pearson; 2018.

Dicionário de Variáveis

Documentando cada variável

O que é um dicionário de variáveis?

Um dicionário de variáveis — também chamado de *codebook* ou *data dictionary* — é um documento que descreve, de forma completa e inequívoca, cada variável de um banco de dados. Broman e Woo, em seu artigo sobre organização de dados em planilhas, recomendam que esse documento seja um arquivo separado, em formato retangular, contendo no mínimo o nome da variável, uma descrição em linguagem natural, a categoria temática e os valores esperados (1).

Na prática da pesquisa em saúde, um bom dicionário de variáveis deve conter:

- **Nome da variável** — exatamente como aparece na planilha de dados (ex: `colesterol`)
- **Rótulo** — descrição em linguagem natural (ex: “Colesterol total sérico”)
- **Tipo** — numérica discreta, numérica contínua, categórica nominal ou categórica ordinal
- **Unidade de medida** — para variáveis numéricas (ex: mg/dL, kg, cm, mmHg)
- **Limites plausíveis** — faixa de valores esperados (ex: colesterol entre 100 e 400 mg/dL)
- **Níveis** — para variáveis categóricas, a lista exaustiva de categorias possíveis e seus significados
- **Código de dados faltantes** — como valores ausentes são representados (ex: `NA`, célula vazia)

Esse documento cumpre três funções essenciais. Primeiro, protege contra erros de interpretação — o caso do Mars Climate Orbiter descrito logo a seguir mostra a importancia desse cuidado. Segundo, permite que outros pesquisadores compreendam e reutilizem seus dados sem

precisar adivinhar o que cada coluna significa. Terceiro, é uma exigência de diretrizes internacionais de relato de pesquisa, como veremos adiante.

A história

Em 23 de setembro de 1999, a sonda Mars Climate Orbiter desapareceu ao tentar entrar na órbita de Marte. Após nove meses de viagem e 125 milhões de dólares investidos, a nave chegou 170 quilômetros mais baixa do que o planejado — e foi destruída na atmosfera marciana ou perdida no espaço (2).

A investigação da NASA revelou uma causa constrangedoramente simples. O software de navegação de solo, desenvolvido pela Lockheed Martin Astronautics, produzia dados de impulso dos propulsores em **libras-força por segundo** (unidades imperiais). O sistema de navegação do Jet Propulsion Laboratory (JPL), que recebia esses dados, assumia que os valores estavam em **newton-segundos** (unidades do Sistema Internacional) — conforme especificado na documentação de interface entre os dois sistemas (2).

Durante os nove meses de travessia, pequenos erros de trajetória se acumularam a cada manobra de correção. O relatório do Mishap Investigation Board listou oito causas contribuintes, entre elas: **“comunicação inadequada entre os elementos do projeto”** e **“o processo de verificação e validação não abordou adequadamente o software de solo”** (2).

O que faltou, em essência, foi algo que qualquer pesquisador em saúde deveria conhecer: um **dicionário de variáveis** — um documento que especifica, para cada dado trocado entre sistemas (ou coletado em um estudo), exatamente o que ele representa, em que unidade está medido e quais são seus limites válidos.

> 💡 **A lição do Mars Climate Orbiter**
>
> Se uma agência espacial com milhares de engenheiros pode perder uma missão inteira por falta de documentação clara sobre unidades de medida, imagine o que

pode acontecer com um banco de dados clínico em que ninguém registrou se o peso está em quilogramas ou libras, se a glicose está em mg/dL ou mmol/L, ou ninguem especificou que se “1” na coluna de óbito significa sim ou não.

Exemplo prático

Vamos construir o dicionário de variáveis completo do nosso banco de dados de pacientes. Este é o tipo de documento que deveria acompanhar qualquer planilha de pesquisa:

Tabela 1: Dicionário de variáveis do estudo — este documento deve acompanhar todo banco de dados.

Variável	Rótulo	Tipo	Unidade	Amplitude observada	Níveis
id	Identificador do paciente	Identificador	—	—	Inteiro único por paciente
sexo	Sexo biológico	Categórica nominal	—	—	female, male
biotipo	Biotipo corporal	Categórica ordinal	—	—	small < medium < large
cidade	Cidade de residência	Categórica nominal	—	—	Buckingham, Louisa
idade	Idade no momento da coleta	Numérica contínua	anos	19 – 92	—
altura	Altura	Numérica contínua	cm	132.1 – 193	—
peso	Peso corporal	Numérica contínua	kg	44.9 – 147.4	—
colesterol	Colesterol total sérico	Numérica contínua	mg/dL	78 – 443	—
hdl	HDL-colesterol	Numérica contínua	mg/dL	12 – 120	—
ratio		Numérica contínua	—	1.5 – 19.3	—

Variável	Rótulo	Tipo	Unidade	Amplitude observada	Níveis
	Razão colesterol total / HDL				
glicose	Glicose de jejum	Numérica contínua	mg/dL	48 – 385	—
glicohemoglobina	Hemoglobina glicada (HbA1c)	Numérica contínua	% (HbA1c)	2.7 – 16.1	—
sistolica	Pressão arterial sistólica	Numérica contínua	mmHg	90 – 250	—
diastolica	Pressão arterial diastólica	Numérica contínua	mmHg	48 – 124	—
cintura	Circunferência da cintura	Numérica contínua	polegadas	26 – 56	—
quadril	Circunferência do quadril	Numérica contínua	polegadas	30 – 64	—

Note que o dicionário inclui variáveis que muitas vezes passam despercebidas — como `cintura` e `quadril`, cujas unidades (polegadas, neste banco de dados) poderiam facilmente ser confundidas com centímetros se não houvesse documentação. Este é exatamente o tipo de ambiguidade que o dicionário elimina.

Crie o dicionário antes de coletar

O momento ideal para construir o dicionário de variáveis é **durante o planejamento do estudo**, antes da coleta de dados. Definir antecipadamente o nome, tipo, unidade e limites de cada variável reduz erros de digitação, inconsistências e retrabalho.

O que o STROBE exige

O STROBE (*Strengthening the Reporting of Observational Studies in Epidemiology*) é um checklist de 22 itens publicado simultaneamente em três grandes revistas médicas — *The Lancet*, *Annals of Internal Medicine* e *PLoS Medicine* — com o objetivo de melhorar a qualidade do relato de estudos observacionais (3).

Dois itens do checklist são diretamente relacionados ao dicionário de variáveis:

- **Item 7 (Variáveis)**: *"Defina claramente todos os desfechos, exposições, preditores, confundidores potenciais e modificadores de efeito. Forneça critérios diagnósticos, se aplicável."*
- **Item 8 (Fontes de dados / mensuração)**: *"Para cada variável de interesse, forneça as fontes de dados e os detalhes dos métodos de avaliação (mensuração). Descreva a comparabilidade dos métodos de avaliação quando houver mais de um grupo."*

O STROBE não usa o termo "dicionário de variáveis", mas o que os itens 7 e 8 exigem é, na prática, exatamente isso: uma documentação completa de cada variável, incluindo sua definição, como foi medida e quais critérios foram usados para classificá-la (3).

Tabela 2: Itens do STROBE relacionados à documentação de variáveis.

Item	Seção	Título	Recomendação
7	Métodos	Variáveis	Definir claramente todos os desfechos, exposições, preditores, confundidores e modificadores de efeito
8	Métodos	Fontes de dados / mensuração	Para cada variável, fornecer fontes de dados e detalhes dos métodos de mensuração
11	Métodos	Variáveis quantitativas	Explicar como variáveis quantitativas foram tratadas na análise; descrever agrupamentos, se aplicável
14a	Resultados	Dados descritivos	Fornecer características dos participantes e informações sobre exposições e confundidores potenciais

A mensagem é clara: publicar um estudo observacional sem documentar adequadamente as variáveis é uma violação das boas práticas internacionais de pesquisa.

Boas práticas de Broman e Woo

Broman e Woo (2018) oferecem um conjunto de recomendações práticas para organização de dados em planilhas que se complementam com o dicionário de variáveis (1). As mais relevantes para este contexto são:

- **Seja consistente**: use sempre o mesmo código para cada categoria. Se o sexo feminino é `female` em um registro, não pode ser `Female`, `F` ou `fem` em outro.
- **Escolha bons nomes**: nomes de variáveis devem ser curtos, descritivos e sem espaços — `colesterol_total` em vez de `Colesterol Total (mg/dL)`. A unidade vai no dicionário, não no nome da variável.
- **Sem células vazias**: use um código explícito para dados faltantes (`NA` no R) em vez de deixar a célula em branco. Células vazias são ambíguas — o dado é faltante ou alguém esqueceu de preencher?
- **Um dado por célula**: não coloque `120/80` na coluna de pressão arterial. Crie duas colunas: `sistolica` e `diastolica`.
- **Formato retangular**: cada linha é uma observação, cada coluna é uma variável, com uma única linha de cabeçalho.
- **Datas em YYYY-MM-DD**: o formato ISO 8601 evita ambiguidades entre formatos americano (MM/DD/YYYY) e brasileiro (DD/MM/YYYY).

Essas recomendações parecem triviais, mas a realidade mostra que são rotineiramente violadas. Auditorias em planilhas reais encontram uma taxa média de erro de 88% (1). O dicionário de variáveis é a primeira linha de defesa contra esse tipo de problema.

Construindo o seu dicionário

1. **Liste todas as variáveis** que pretende coletar — antes de criar a planilha.

2. **Defina o tipo** de cada uma (numérica discreta, contínua, categórica nominal, ordinal).
3. **Especifique a unidade de medida** para todas as numéricas.
4. **Estabeleça limites plausíveis** — valores fora dessa faixa devem disparar um alerta de revisão.
5. **Liste todos os níveis** de cada variável categórica, com descrição do que cada um significa.
6. **Defina o código de dados faltantes** — e use-o de forma consistente.
7. **Salve o dicionário como um arquivo separado** — nunca dentro da planilha de dados.

O dicionário é um documento vivo: pode ser atualizado ao longo do estudo, mas as decisões fundamentais devem estar registradas antes da coleta.

> ⓘ **Próximos passos**
>
> - **Capítulo 4** — Dados numéricos em profundidade
> - **Capítulo 5** — Dados categóricos em profundidade
> - **Capítulo 6** — Casos especiais que desafiam a classificação

---

Referências

1. Broman KW, Woo KH. Data Organization in Spreadsheets. The American Statistician. 2018;72(1):2–10.
2. Mars Climate Orbiter Mishap Investigation Board. Mars Climate Orbiter Mishap Investigation Board Phase I Report. NASA; 1999 nov.
3. von Elm E, Altman DG, Egger M, Pocock SJ, Gøtzsche PC, Vandenbroucke JP. The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) Statement: Guidelines for Reporting Observational Studies. The Lancet. 2007;370(9596):1453–7.

Dados Numéricos

Discretos, contínuos e tudo o que podemos medir

A história

Em 1835, o astrônomo e matemático belga Adolphe Quetelet publicou *Sur l'Homme et le Développement de ses Facultés* — um tratado ambicioso que propunha aplicar à sociedade humana os mesmos métodos que a astronomia usava para medir estrelas. Quetelet coletou milhares de medidas de altura, peso e perímetro torácico de soldados e civis, e descobriu algo que o fascinava: quando agrupadas, essas medições formavam uma curva em sino — a distribuição normal — com notável regularidade. Ele chamou o centro dessa curva de *l'homme moyen*: o "homem médio" (1,2).

A ideia era revolucionária. Até então, variações individuais eram vistas como erros de observação — ruído a ser eliminado. Quetelet inverteu a lógica: a **variação** entre indivíduos era real e mensurável, e a **média** era uma descrição legítima do grupo. Nasciam ali dois conceitos que até hoje são a base de qualquer análise de dados numéricos: a tendência central e a dispersão.

Mais de um século depois, em 1977, John Tukey publicou *Exploratory Data Analysis*, um livro que mudaria a forma como estatísticos olham para números antes de testá-los. A premissa de Tukey era direta: **"É importante entender o que você pode fazer antes de aprender a medir quão bem você parece ter feito"** (3). Em vez de começar com hipóteses e testes formais, Tukey propunha que o analista primeiro *explorasse* seus dados — usando gráficos simples, resumos numéricos e ferramentas visuais como o diagrama de ramo-e-folhas e o boxplot. A exploração revelaria padrões, anomalias e surpresas que testes confirmatórios jamais detectariam sozinhos.

A lição conjunta de Quetelet e Tukey é o tema deste capítulo: dados numéricos carregam informação rica — média, dispersão, forma, outliers

— mas essa riqueza só se revela quando sabemos o que procurar e como descrever.

> 💡 **A lição de Tukey**
>
> Antes de testar, explore. Antes de modelar, descreva. A análise exploratória não é um passo opcional — é o primeiro passo.

O que são dados numéricos?

Dados numéricos (ou quantitativos) representam **quantidades mensuráveis**. São valores sobre os quais operações aritméticas — soma, subtração, média, desvio-padrão — produzem resultados com significado. No R, são armazenados como `integer` (inteiros) ou `numeric`/`double` (decimais).

A definição parece simples, mas carrega uma implicação profunda: se um valor é numérico, a **distância** entre dois valores tem significado. A diferença entre 120 e 140 mmHg de pressão sistólica (20 mmHg) é a mesma que entre 140 e 160 mmHg. Isso não ocorre com dados categóricos ordinais — a distância entre “leve” e “moderado” não é necessariamente igual à distância entre “moderado” e “grave”.

No nosso banco de dados, a maioria das variáveis é numérica:

Tabela 1: Variáveis numéricas do estudo — cada uma com unidade e tipo de medição definidos.

Variável	Unidade	Tipo	Instrumento / origem
idade	anos	Contínua*	Registro civil
colesterol	mg/dL	Contínua	Dosagem laboratorial
glicose	mg/dL	Contínua	Dosagem laboratorial
hdl	mg/dL	Contínua	Dosagem laboratorial
ratio	adimensional	Contínua	Calculado (colesterol/hdl)
glicohemoglobina	% (HbA1c)	Contínua	Dosagem laboratorial
peso	kg	Contínua	Balança
altura	cm	Contínua	Estadiômetro

Variável	Unidade	Tipo	Instrumento / origem
sistolica	mmHg	Contínua	Esfigmomanômetro
diastolica	mmHg	Contínua	Esfigmomanômetro
cintura	cm	Contínua	Fita métrica
quadril	cm	Contínua	Fita métrica

* A variável `idade` merece uma discussão à parte — veja o callout mais adiante.

Discretos vs. contínuos

A distinção mais fundamental entre dados numéricos é entre **discretos** e **contínuos**. Embora o Capítulo 2 já tenha introduzido essa classificação, aqui a aprofundamos com exemplos, critérios e casos-limite.

Variáveis numéricas discretas

Dados discretos assumem valores inteiros e finitos (ou infinitos enumeráveis), sem frações significativas no contexto da medição. Um teste prático ajuda a identificá-los: se, para qualquer par de valores observados, o valor intermediário **não faz sentido** no contexto da variável, ela é discreta (4). Entre 5 e 8 lesões, “6,5 lesões” não existe. Não faz sentido dizer que um paciente teve 2,7 internações ou que uma família tem 1,3 filhos.

Tabela 2: Exemplos de variáveis numéricas discretas em pesquisa em saúde.

Variável	Valores possíveis	Operação	Distribuição típica
Número de internações	0, 1, 2, 3, …	Contagem	Poisson
Número de filhos	0, 1, 2, 3, …	Contagem	Poisson
Quantidade de medicamentos	0, 1, 2, 3, …	Contagem	Poisson
Número de consultas/ano	0, 1, 2, 3, …	Contagem	Poisson

Variável	Valores possíveis	Operação	Distribuição típica
Número de lesões cutâneas	0, 1, 2, 3, …	Contagem	Poisson / Binomial negativa
Número de dentes cariados	0, 1, 2, 3, …	Contagem	Binomial

Variáveis numéricas contínuas

Dados contínuos podem assumir qualquer valor dentro de um intervalo — incluindo frações arbitrariamente precisas. A precisão é limitada apenas pelo **instrumento de medida**, não pela natureza da variável.

O mesmo teste prático funciona ao inverso: se, para qualquer par de valores, o valor intermediário **faz sentido**, a variável é contínua (4). Entre um paciente com 72,0 kg e outro com 74,0 kg, um paciente com 73,0 kg é perfeitamente plausível — assim como 72,5 ou 73,217 kg.

Tabela 3: Variáveis numéricas contínuas do estudo — amplitude e estatísticas descritivas.

Variável	Unidade	n válidos	Mín	Máx	Média	DP
colesterol	mg/dL	402	78.00	443.00	207.8	44.4
glicose	mg/dL	403	48.00	385.00	106.7	53.1
hdl	mg/dL	402	12.00	120.00	50.4	17.3
glicohemoglobina	% (HbA1c)	390	2.68	16.11	5.6	2.2
peso	kg	402	44.91	147.42	80.6	18.3
altura	cm	398	132.08	193.04	167.7	10.0
sistolica	mmHg	398	90.00	250.00	136.9	22.7
diastolica	mmHg	398	48.00	124.00	83.3	13.6

⚠ **Idade: discreta ou contínua?**

No nosso banco de dados, a variável `idade` aparece registrada como números inteiros (19, 23, 45, …). Isso torna a idade uma variável discreta? A resposta exige cuidado.

O tempo — e, portanto, o envelhecimento — é um fenômeno intrinsecamente contínuo. O fato de a idade ser comumente expressa em anos inteiros não a

transforma em variável discreta: o que define a natureza da escala não são os valores efetivamente registrados, mas o **potencial da escala de acomodar valores decimais** (5). A prova é que a idade de crianças é rotineiramente expressa em meses e a de neonatos em dias — precisamente porque a precisão em anos inteiros seria insuficiente.

Um teste simples ajuda a esclarecer: se, para qualquer par de valores observados, o valor intermediário é significativo, a variável é contínua (4). Entre um paciente de 40 anos e outro de 41, um paciente de 40,5 anos faz perfeito sentido — diferentemente de "6,5 lesões", que não faz.

Na prática da pesquisa, a maioria dos artigos sequer especifica *como* a idade foi calculada — se na admissão, na inclusão no estudo ou no momento do desfecho — e se foram considerados meses ou apenas anos inteiros (6).

O risco maior, porém, está em **categorizar** a idade em faixas etárias quando isso não é necessário. Altman e Royston demonstram que dicotomizar uma variável contínua pela mediana reduz o poder estatístico tanto quanto descartar um terço dos dados (7). A recomendação é clara: sempre que possível, mantenha a idade como variável contínua na análise.

Em resumo: a idade é uma variável **contínua por natureza**, frequentemente **registrada de forma discreta** (em anos inteiros) e por vezes indevidamente **categorizada** em faixas etárias. Reconhecer essa distinção é fundamental para escolher a análise estatística correta.

Escalas intervalar e de razão: uma distinção que ficou na teoria

Nos capítulos anteriores, classificamos variáveis em dois grandes grupos: numéricas e categóricas. Peso é numérico. Sexo é categórico. Pressão arterial é numérica. Tipo sanguíneo é categórico. Essa divisão é intuitiva, funciona bem na prática e guia praticamente todas as decisões que tomamos ao escolher um teste estatístico ou um tipo de gráfico.

Mas quem já cursou uma disciplina de bioestatística — ou folheou um livro-texto antes de chegar a este — provavelmente aprendeu uma classificação mais detalhada. Não dois tipos, mas quatro: nominal, ordinal, intervalar e de razão. A sigla NOIR (*Nominal, Ordinal, Interval, Ratio*), proposta por Stevens em 1946, aparece em praticamente todo

curso introdutório e foi apresentada no Capítulo 2 deste livro (8). E se nominal e ordinal correspondem ao que chamamos de categórico, o ramo numérico deveria, pela lógica de Stevens, ser subdividido em mais dois: intervalar e de razão.

A diferença entre escalas intervalar e de razão se resume a uma pergunta: **o zero da escala significa ausência da grandeza?**

Na **escala intervalar**, o zero é arbitrário — não representa ausência da grandeza. O exemplo clássico é a temperatura em graus Celsius: 0 °C não significa "ausência de temperatura", mas sim o ponto de congelamento da água. Consequência: podemos calcular diferenças (a diferença entre 20 °C e 30 °C são 10 °C), mas não razões (30 °C não é "o dobro" de 15 °C em termos de calor).

Na **escala de razão**, o zero é absoluto — representa ausência da grandeza. Peso, altura, concentração de colesterol e pressão arterial são exemplos. Um paciente com 80 kg pesa exatamente o dobro de um com 40 kg. As quatro operações aritméticas e todas as estatísticas descritivas são válidas.

Tabela 4: Comparação entre escalas intervalar e de razão — a diferença está no zero.

Aspecto	Escala intervalar	Escala de razão
Zero	Arbitrário (convenção)	Absoluto (ausência da grandeza)
Diferenças	Significativas (10 °C de diferença)	Significativas (10 kg de diferença)
Razões	Sem sentido (30 °C ≠ 2 × 15 °C)	Significativas (80 kg = 2 × 40 kg)
Exemplo clínico	Temperatura em °C, ano calendário	Peso (kg), colesterol (mg/dL), altura (cm)
Estatísticas	Média, DP, correlação de Pearson	Todas + média geométrica, CV

Por que essa distinção ficou na teoria

A distinção é conceitualmente correta. Mas na prática da análise de dados — especialmente em saúde — ela perdeu relevância por quatro razões convergentes.

O software não a reconhece. As duas linguagens dominantes na análise de dados em saúde — R e Python — organizam suas variáveis em tipos que *não incluem* a distinção intervalar/razão. No R, uma variável numérica é `numeric` ou `integer`; uma categórica é `factor`. No Python (pandas), temos `float64` e `category`. Em nenhum dos dois ambientes existe um tipo `interval` separado de `ratio`. Quando a ferramenta que o mundo inteiro usa para analisar dados não reconhece uma distinção, é um sinal forte de que essa distinção não muda as decisões práticas de análise.

As operações estatísticas são as mesmas. Média, desvio-padrão, teste *t*, ANOVA, correlação de Pearson, regressão linear — todas essas ferramentas pressupõem apenas que as **distâncias** entre valores são significativas, o que é verdade tanto para escalas intervalares quanto para escalas de razão. A única operação que a escala de razão permite e a intervalar não — a razão entre valores (ex: "o dobro") — raramente aparece como parte de um teste estatístico formal.

Variáveis intervalares são raras em saúde. Na pesquisa clínica e epidemiológica, a grande maioria das variáveis numéricas é de razão: peso, altura, pressão, colesterol, glicose, frequência cardíaca, contagens celulares. Os exemplos clássicos de escala intervalar — temperatura em °C, ano calendário, escore de QI — aparecem com pouca frequência em bancos de dados clínicos. Uma distinção que raramente se aplica é uma distinção que raramente importa.

A literatura aponta na mesma direção. Velleman e Wilkinson, em uma crítica influente à taxonomia de Stevens, concluem que a distinção operacional relevante na prática é entre *"categorical factors"* (nominais e ordinais) e *"continuous covariates"* (intervalares e de razão) — exatamente a divisão que adotamos neste livro. A seção 7 de seu artigo é intitulada, significativamente, *"Good data analysis does not assume data types"*, e a seção 8 conclui que *"the scale type of data depends on the questions we intend to ask"* (9). Agresti, em seu livro-texto de referência, organiza a classificação principal em *"quantitative"* e *"categorical"*, apresentando a subdivisão intervalar/razão como nota conceitual, não como divisor de análise (10). Norman demonstra que

testes paramétricos produzem resultados válidos independentemente de o dado ser intervalar ou de razão — a robustez a violações de pressupostos de escala é documentada há décadas (11).

O que adotamos neste livro

Diante dessas evidências, este livro trabalha com a classificação em dois grandes ramos: **numérico** (discreto ou contínuo) e **categórico** (nominal ou ordinal). Essa é a divisão que determina as decisões reais do dia a dia: se usamos média ou proporção, histograma ou barras, teste *t* ou qui-quadrado.

> **A distinção intervalar/razão importa quando?**
>
> Em alguns contextos específicos, a diferença entre escalas intervalar e de razão pode ser relevante — por exemplo, na interpretação do coeficiente de variação (que pressupõe zero absoluto) ou no uso da média geométrica. Mas, para a grande maioria das análises em saúde, a pergunta que realmente muda a abordagem é: **o dado é numérico ou categórico?**

Descrevendo dados numéricos

Descrever adequadamente uma variável numérica exige responder a três perguntas: **onde estão os dados?** (tendência central), **quão espalhados estão?** (dispersão) e **qual a forma da distribuição?** (simetria, outliers).

Medidas de tendência central

As três medidas clássicas — média, mediana e moda — respondem de formas diferentes à pergunta “qual é o valor típico?”.

Tabela 5: Medidas de tendência central para variáveis selecionadas do estudo.

Variável	Média	Mediana	Diferença	Interpretação
colesterol	207.8	204.0	3.8	Assimetria à direita (cauda longa para valores altos)
glicose	106.7	89.0	17.7	Assimetria à direita (cauda longa para valores altos)

Variável	Média	Mediana	Diferença	Interpretação
peso	80.6	78.2	2.4	Assimetria à direita (cauda longa para valores altos)
idade	46.9	45.0	1.9	Distribuição aproximadamente simétrica
sistolica	136.9	136.0	0.9	Distribuição aproximadamente simétrica

Quando a média e a mediana são próximas, a distribuição tende a ser simétrica. Quando divergem, há assimetria — e a mediana é geralmente a medida mais representativa do "valor típico", pois é menos influenciada por valores extremos (12).

Medidas de dispersão

A tendência central sozinha não basta. Dois grupos podem ter a mesma média e distribuições completamente diferentes. As medidas de dispersão capturam essa variabilidade.

Tabela 6: Medidas de dispersão para variáveis selecionadas do estudo.

Variável	Desvio-padrão	Intervalo interquartil	Amplitude
colesterol	44.4	51.0	365.0
glicose	53.1	25.0	337.0
peso	18.3	22.2	102.5
idade	16.3	26.0	73.0
sistolica	22.7	25.5	160.0

O **desvio-padrão** (DP) é a medida mais usada: quanto maior, mais os dados se espalham ao redor da média. O **intervalo interquartil** (IIQ) — a diferença entre o percentil 75 e o percentil 25 — é robusto a outliers e complementa a mediana da mesma forma que o DP complementa a média. A **amplitude** (máximo − mínimo) é simples mas muito sensível a valores extremos.

A forma da distribuição

A **distribuição** de uma variável numérica revela padrões que nenhuma estatística isolada consegue capturar: simetria, caudas longas, picos

múltiplos e valores atípicos. É aqui que a lição de Tukey se materializa — a exploração visual é insubstituível (3).

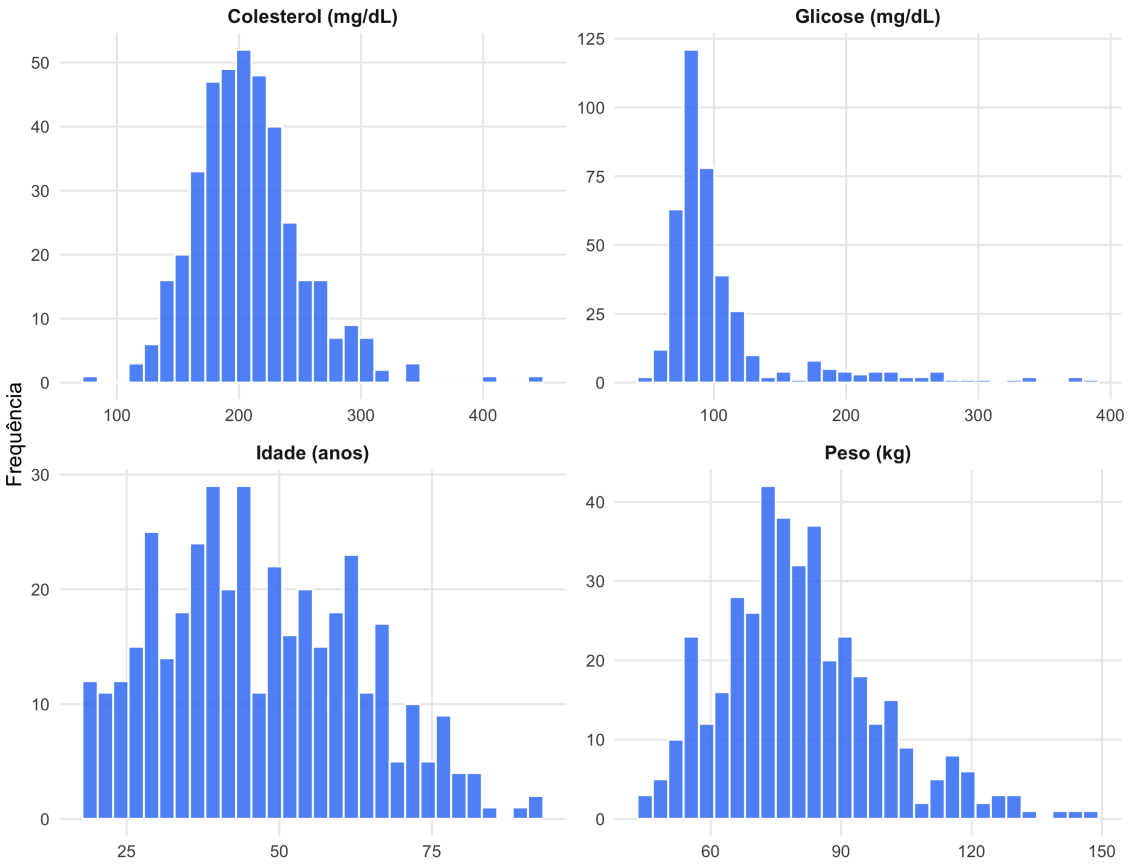

Figura 1: Distribuição de quatro variáveis numéricas — note a diferença de forma entre elas.

Observe como as distribuições diferem: a idade e o peso apresentam distribuições mais simétricas, enquanto a glicose apresenta forte assimetria à direita — com uma cauda longa de valores elevados, típica de variáveis metabólicas em populações que incluem pacientes diabéticos.

O boxplot: cinco números que contam uma história

O boxplot (diagrama de caixa) é talvez a ferramenta mais elegante que Tukey legou à estatística. Com apenas cinco números — mínimo, primeiro quartil (Q1), mediana, terceiro quartil (Q3) e máximo — ele resume a distribuição inteira e ainda identifica valores atípicos (3).

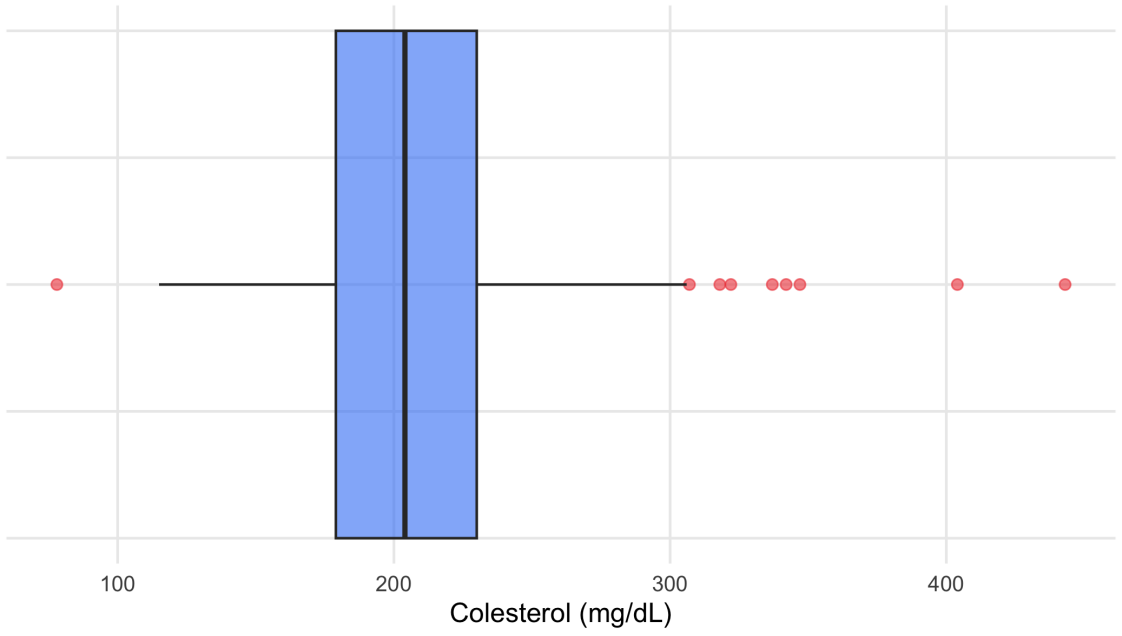

Figura 2: Anatomia do boxplot — os cinco números de Tukey aplicados ao colesterol do estudo.

A **caixa** cobre o intervalo interquartil (IIQ = Q3 − Q1), contendo os 50% centrais dos dados. A **linha central** é a mediana. Os **bigodes** se estendem até o valor mais extremo que esteja dentro de 1,5 × IIQ a partir da caixa. Pontos além dos bigodes são sinalizados como potenciais **outliers** — valores que merecem investigação (não necessariamente exclusão).

O boxplot é especialmente útil para **comparar grupos**:

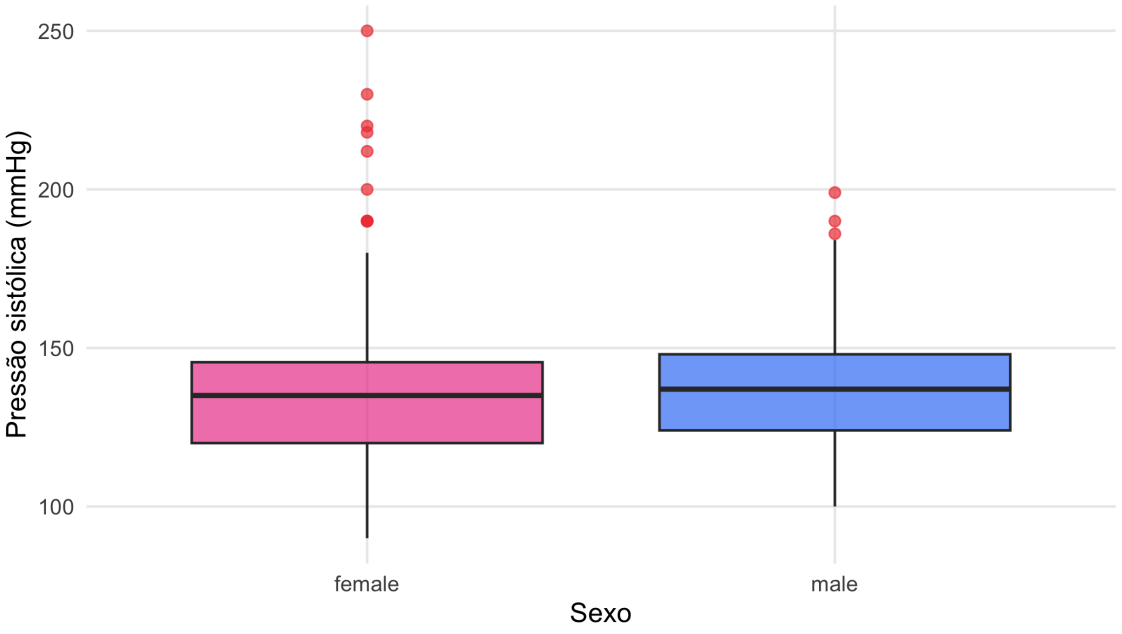

Figura 3: Comparação da pressão sistólica entre sexos — o boxplot revela diferenças de mediana, dispersão e outliers.

O resumo dos cinco números

O *five-number summary* de Tukey — mínimo, Q1, mediana, Q3 e máximo — é a base do boxplot e uma forma poderosa de descrever qualquer variável numérica sem pressupor simetria ou normalidade (3).

Tabela 7: Resumo dos cinco números para as variáveis numéricas do estudo.

Variável	Mín	Q1	Mediana	Q3	Máx
idade	19.0	34.0	45.0	60.0	92.0
colesterol	78.0	179.0	204.0	230.0	443.0
glicose	48.0	81.0	89.0	106.0	385.0
hdl	12.0	38.0	46.0	59.0	120.0
peso	44.9	68.5	78.2	90.7	147.4
altura	132.1	160.0	167.6	175.3	193.0
sistolica	90.0	121.2	136.0	146.8	250.0
diastolica	48.0	75.0	82.0	90.0	124.0

Como reportar dados numéricos

A forma de reportar uma variável numérica depende da simetria de sua distribuição. As duas convenções mais comuns na literatura em saúde são:

Tabela 8: Convenções para reportar dados numéricos em artigos científicos.

Situação	Como reportar	Exemplo do estudo	Teste de comparação
Distribuição simétrica (aproximadamente normal)	Média ± desvio-padrão (DP)	Colesterol: 207,8 ± 44,4 mg/dL	Teste t, ANOVA
Distribuição assimétrica ou com outliers	Mediana (intervalo interquartil: Q1 – Q3)		

Situação	Como reportar	Exemplo do estudo	Teste de comparação
		Glicose: 90,0 (81,0 – 106,0) mg/dL	Mann-Whitney, Kruskal-Wallis

Não misture as convenções

Se a variável é reportada como mediana (IIQ), o teste de comparação deve ser não paramétrico (Mann-Whitney, Kruskal-Wallis). Se é reportada como média ± DP, o teste correspondente é o paramétrico (teste *t*, ANOVA). A coerência entre a estatística descritiva e o teste inferencial é fundamental — e revisores de periódicos frequentemente apontam essa inconsistência (7).

Transformações: quando os dados não cooperam

Variáveis com distribuição muito assimétrica — como a glicose no nosso estudo — podem dificultar a aplicação de métodos que pressupõem normalidade. Uma estratégia comum é aplicar uma **transformação matemática** que aproxime a distribuição de uma forma mais simétrica.

A transformação mais usada é o **logaritmo natural** (ln). Ela comprime os valores mais altos mais intensamente do que os mais baixos, o que frequentemente reduz a assimetria à direita.”

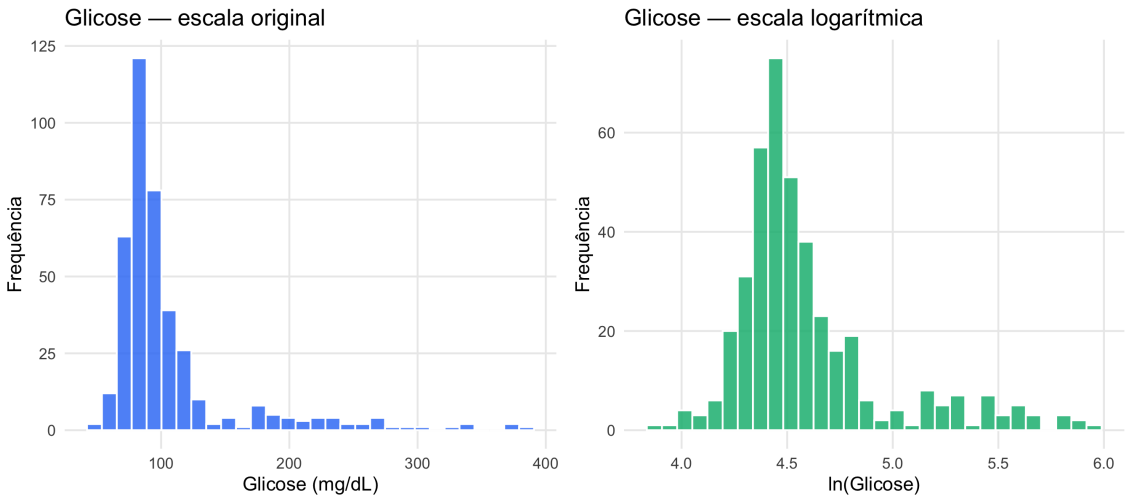

Figura 4: Efeito da transformação logarítmica sobre a distribuição da glicose.

A transformação logarítmica é especialmente útil para variáveis biológicas estritamente positivas e com assimetria à direita, como concentrações sanguíneas, tempos de reação e algumas medidas laboratoriais. Em muitos casos, ela reduz a assimetria e estabiliza a variabilidade, o que pode tornar mais apropriado o uso de métodos paramétricos. Após a análise, os resultados podem ser reexpressos na escala original; por exemplo, a média dos valores transformados em log, quando retransformada, corresponde à média geométrica. (12).

> ⓘ **Cuidado com a interpretação**
>
> A transformação facilita a análise estatística, mas os **resultados devem ser interpretados na escala original**. Uma diferença de 0,3 em ln(glicose) não é intuitiva para o clínico — é preciso converter de volta para mg/dL.

Resumo do capítulo

Tabela 9: Resumo — dados numéricos em pesquisa em saúde.

Conceito	Definição	Exemplo do estudo
Variáveis discretas	Resultado de contagem; valores inteiros sem frações significativas	Nº de internações, nº de filhos
Variáveis contínuas	Resultado de medição; qualquer valor em um intervalo contínuo	Peso (kg), colesterol (mg/dL), pressão (mmHg)
Escala intervalar	Zero arbitrário; diferenças significativas, razões sem sentido	Temperatura (°C), ano calendário
Escala de razão	Zero absoluto; todas as operações aritméticas são válidas	Peso (kg), altura (cm), colesterol (mg/dL)
Tendência central	Média (distribuição simétrica) ou mediana (assimétrica)	Colesterol: média = 207,8; Glicose: mediana = 90,0
Dispersão	DP (com a média) ou IIQ (com a mediana)	Colesterol: DP = 44,4; Glicose: IIQ = 81,0 – 106,0
Boxplot	Resumo visual dos cinco números de Tukey — revela centro, dispersão e outliers	Comparação de pressão sistólica entre sexos

Conceito	Definição	Exemplo do estudo
Transformação logarítmica	Comprime assimetria à direita; útil para variáveis biológicas	Glicose em escala log → distribuição simétrica

> ⓘ **Próximos passos**
>
> Este capítulo explorou os dados numéricos — sua classificação, descrição e visualização. No próximo capítulo, faremos o mesmo percurso para os **dados categóricos**: nominais, ordinais e as armadilhas de tratar categorias como números.

Referências

1. Quetelet A. Sur l'Homme et Le Développement de Ses Facultés, Ou Essai de Physique Sociale. Paris: Bachelier; 1835.
2. Stigler SM. The History of Statistics: The Measurement of Uncertainty before 1900. Cambridge, MA: Harvard University Press; 1986.
3. Tukey JW. Exploratory Data Analysis. Reading, MA: Addison-Wesley; 1977.
4. Kaliyadan F, Kulkarni V. Types of Variables, Descriptive Statistics, and Sample Size. Indian dermatology online journal. 2019 Jan-Feb;10(1):82–6.
5. Andrade C. Age as a Variable: Continuous or Categorical? Indian Journal of Psychiatry. outubro de 2017;59:524–5.
6. Voor in 't holt AF. Age: A Variable Whose Definition We Should Not Ignore. Infection Control & Hospital Epidemiology. 2019;40(12):1444–5.
7. Altman DG, Royston P. The Cost of Dichotomising Continuous Variables. BMJ (Clinical research ed). 2006;332(7549):1080.
8. Stevens SS. On the Theory of Scales of Measurement. Science. 1946;103(2684):677–80.
9. Velleman PF, Wilkinson L. Nominal, Ordinal, Interval, and Ratio Typologies Are Misleading. The American Statistician. 1993;47(1):65–72.
10. Agresti A. Statistical Methods for the Social Sciences. 5.ª ed. Boston: Pearson; 2018.
11. Norman G. Likert Scales, Levels of Measurement and the «Laws» of Statistics. Advances in Health Sciences Education. 2010;15(5):625–32.
12. Freedman DA, Pisani R, Purves RA. Statistics. 4.ª ed. New York: W. W. Norton & Company; 2007.

Dados Categóricos

Nominais, ordinais, binários

A história

Em 1662, um comerciante de tecidos londrino chamado John Graunt publicou um pequeno livro que mudaria a história da saúde pública: *Natural and Political Observations upon the Bills of Mortality*. Graunt não era médico, nem matemático — era um mercador curioso que decidiu examinar sistematicamente os registros semanais de mortes em Londres, os chamados *Bills of Mortality*, que a igreja publicava desde o século XVI (1,2).

O que Graunt fez com esses registros foi extraordinariamente original: ele **categorizou**. Cada óbito era classificado por causa — “consumptyon” (tuberculose), “plague” (peste), “drowned” (afogamento), “aged” (velhice), “teeth” (problemas dentários em crianças). A partir dessas categorias, ele construiu **tabelas de frequência** — possivelmente as primeiras da história — e descobriu padrões que ninguém havia notado: que a proporção de mortes por causas violentas era surpreendentemente estável de ano para ano; que os nascimentos masculinos superavam os femininos numa razão constante de 14 para 13; e que, em anos sem peste, a mortalidade urbana era maior que a rural (1,3).

Graunt também enfrentou um problema que todo pesquisador moderno reconhecerá: as categorias não eram padronizadas. Uma morte registrada como “teeth” em uma paróquia podia ser registrada como “convulsion” em outra. O mesmo óbito podia ser atribuído a “fever” ou a “spotted feaver” dependendo de quem preenchia o formulário. Graunt precisou **decidir** como agrupar, renomear e consolidar essas categorias para que suas tabelas fizessem sentido — exercendo, sem saber, o papel que todo pesquisador exerce ao definir os níveis de uma variável categórica.

Com esse trabalho, Graunt é considerado o fundador da demografia e um dos pais da epidemiologia. Seu legado mais duradouro, porém, foi demonstrar que **contar categorias** — algo aparentemente trivial — é uma das ferramentas mais poderosas da ciência.

> **A lição de Graunt**
>
> Dados categóricos não são dados "simples". A decisão de *quais categorias criar* e *como agrupar* os casos é uma decisão metodológica com consequências diretas para as conclusões. Graunt sabia disso em 1662 — e a lição continua válida.

O que são dados categóricos?

Dados categóricos (ou qualitativos) representam **qualidades**. Não faz sentido calcular a "média" de uma variável categórica — a média de "feminino" e "masculino" não existe (4). A diferença fundamental em relação aos dados numéricos é que, para dados categóricos, as operações aritméticas (soma, subtração, média) **não têm significado**. As operações que fazem sentido são **contar** (quantos sujeitos em cada categoria) e **comparar proporções** (que fração do total pertence a cada grupo).

Dados categóricos se subdividem em dois tipos, de acordo com a existência ou não de uma ordem entre as categorias. Quando as categorias não possuem hierarquia chamamos a variável de nominal. Quando existe uma ordenação natural entre os níveis chamamos de ordinal. As variáveis nominais, quando tem apenas dois níveis, são um tipo especial de variáveis nominais, usualmente chamadas de nominais binárias.

Tabela 1: Exemplos de variáveis categóricas em pesquisa em saúde — nominais, binárias e ordinais.

Variável	Níveis	Nº de níveis	Ordem?
Nominais			
Tipo sanguíneo	A, B, AB, O	4	Não
Cor dos olhos	castanho, azul, verde, ...	variável	Não
Sexo	masculino, feminino, outro	3	Não

Variável	Níveis	Nº de níveis	Ordem?
Nominais binárias			
Diagnóstico	presente, ausente	2	Não
Óbito	sim, não	2	Não
Exposição	sim, não	2	Não
Ordinais			
Estadiamento do câncer	I < II < III < IV	4	Sim
Escala de dor	leve < moderada < intensa	3	Sim
Classe funcional (NYHA)	I < II < III < IV	4	Sim

Categóricos Nominais: categorias sem ordem

Dados nominais classificam sujeitos em categorias **sem qualquer relação de hierarquia**. Reorganizar os níveis em qualquer sequência não altera o significado — "A, B, AB, O" é tão válido quanto "O, A, B, AB" (4,5).

A única operação de comparação possível é a de **igualdade**: dois sujeitos estão na mesma categoria ou em categorias diferentes. Não existe "maior" ou "menor" entre os níveis.

Exemplos em saúde: tipo sanguíneo (A, B, AB, O), sexo (feminino, masculino), cor dos olhos, estado civil, cidade de residência, diagnóstico principal (infarto, AVC, pneumonia).

No nosso estudo, as variáveis `sexo` e `cidade` são nominais. A forma natural de apresentar dados nominais é a **tabela de frequência** — exatamente como Graunt fazia no século XVII. A tabela mostra quantos sujeitos pertencem a cada categoria (*frequência absoluta*, n) e qual fração do total cada categoria representa (*frequência relativa*, %).

Tabela 2: Distribuição de frequência da variável sexo — uma variável nominal binária.

Sexo	n	%	IC 95%
female	234	58.1	53.3 – 62.9

Sexo	n	%	IC 95%
male	169	41.9	37.1 – 46.7

Tabela 3: Distribuição de frequência da variável cidade.

Cidade	n	%
Buckingham	200	49.6
Louisa	203	50.4

Quando a variável tem poucas categorias — como `sexo`, com apenas dois níveis — a tabela é suficiente. Mas quando há muitas categorias, o **gráfico de barras** torna a comparação visual imediata. No dataset `beer`, que contém mais de 8.000 cervejas artesanais de diversos países, a variável `country` é nominal com dezenas de níveis. Vejamos os dez países com maior número de rótulos:

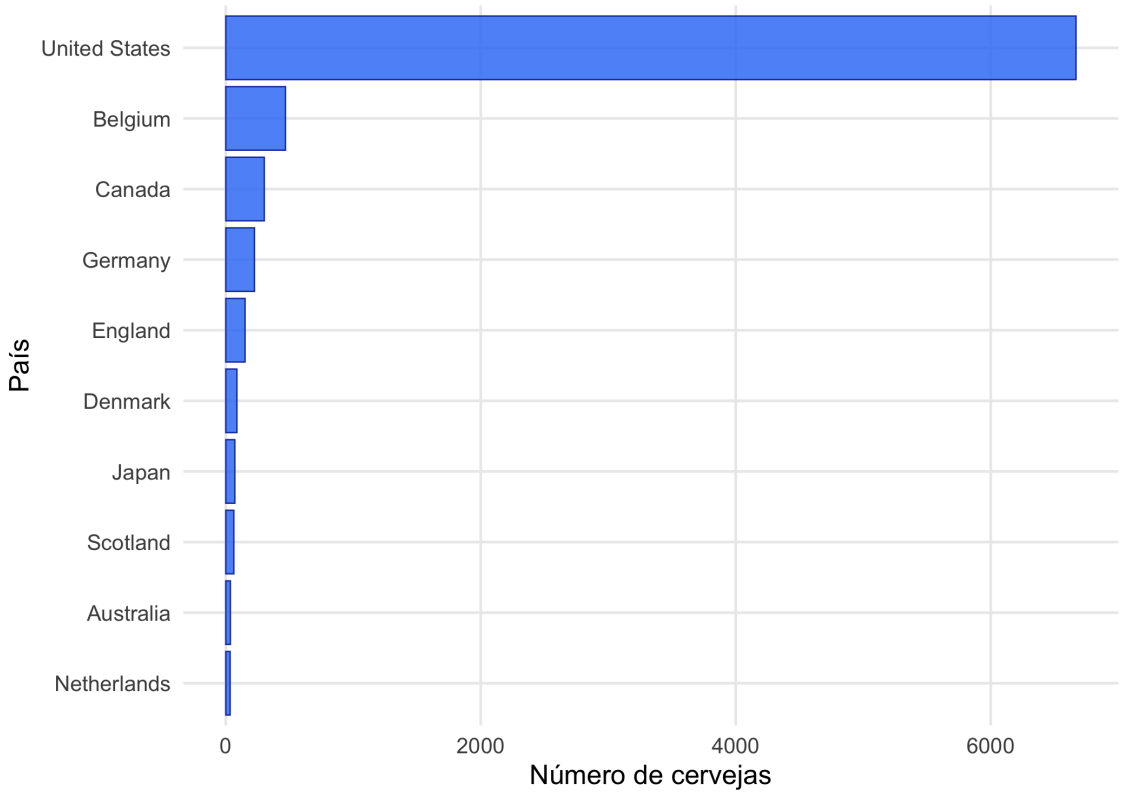

Figura 1: Gráfico de barras para o país de origem — uma variável nominal. A ordem das barras é arbitrária (aqui, por frequência), porque não existe hierarquia entre países.

Note que as barras estão ordenadas por frequência — mas poderiam estar em ordem alfabética ou qualquer outra. Para dados nominais, **a ordem das barras é uma escolha estética**, não uma propriedade dos

dados. Reorganizar os países não muda a informação, mas torna o gráfico muito mais fácil de interpretar.

Categóricos Nominais binários

Um caso particular — e extremamente frequente em saúde — são as variáveis nominais com exatamente **dois níveis**: as variáveis **binárias** (ou dicotômicas). Exemplos: diagnóstico (presente/ausente), desfecho (óbito/alta), exposição (sim/não), teste diagnóstico (positivo/negativo).

Variáveis binárias ocupam uma posição especial na estatística porque podem ser codificadas como 0 e 1 — o que permite calcular a **proporção** diretamente como uma média aritmética. Se codificamos “male” = 1 e “female” = 0, a média da variável será a proporção de homens na amostra. Essa propriedade é a base de modelos como a regressão logística.

> ⓘ **Binária nominal ≠ binária numérica**
>
> Quando codificamos sexo como 0 e 1, estamos criando uma representação numérica de uma variável categórica. Os números são **rótulos**, não magnitudes — o “1” não é “maior” que o “0” em termos de grandeza. Essa distinção é crucial para não tratar uma codificação como uma medição.

Categóricos Ordinais

Dados ordinais classificam sujeitos em categorias que possuem uma **hierarquia natural** — uma relação de “maior que” ou “menor que” — mas cujas **distâncias entre os níveis não são necessariamente iguais** (4,5).

Sabemos que um tumor em estágio III é mais avançado que um em estágio II. Mas não podemos afirmar que a “distância” entre estágio I e II é a mesma que entre II e III — a progressão tumoral não segue incrementos uniformes.

Exemplos em saúde: estadiamento de câncer (I < II < III < IV), classe funcional NYHA (I–IV), escala de dor (leve < moderada < intensa),

classificação ASA de risco cirúrgico (I–V), escolaridade (fundamental < médio < superior).

No nosso estudo, a variável `biotipo` é ordinal:

Tabela 4: Distribuição do biotipo — uma variável ordinal. A ordem dos níveis importa.

Biotipo	n	%	% acumulado
small	104	26.6	26.6
medium	184	47.1	73.7
large	103	26.3	100.0

Note a coluna **% acumulado** — ela faz sentido para dados ordinais (57,6% dos pacientes são *small* ou *medium*), mas **não faria sentido** para dados nominais (o "% acumulado" de tipo sanguíneo A + B não tem interpretação útil).

Para ilustrar melhor a importância da ordenação, vejamos outro exemplo. O dataset `escolaridade` contém 300 registros fictícios com proporções baseadas na PNAD Contínua. A variável `escolaridade` tem seis níveis ordenados — de "Fundamental incompleto" a "Pós-graduação". Quando representamos essa variável num gráfico de barras, **a ordem das barras deve respeitar a hierarquia dos níveis**:

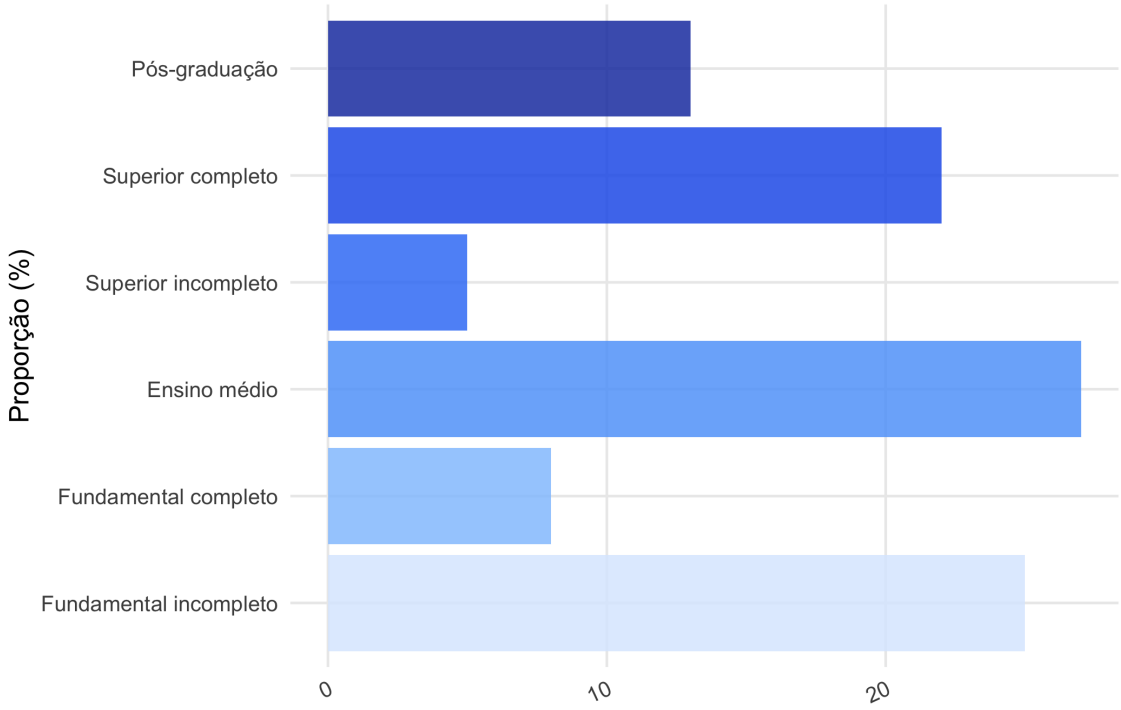

Figura 2: Escolaridade em ordem correta — as barras seguem a hierarquia natural dos níveis, do menor para o maior grau de instrução.

Compare com o que acontece quando deixamos o software ordenar as categorias por conta própria — geralmente em ordem **alfabética**:

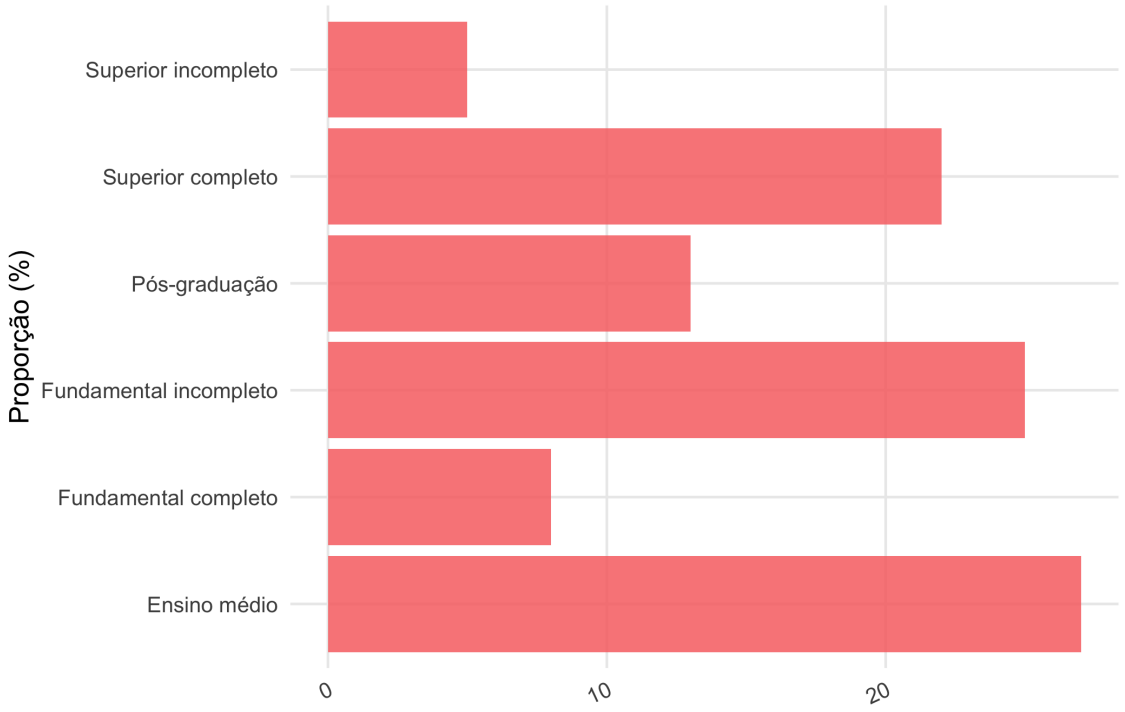

Figura 3: Escolaridade em ordem alfabética — a hierarquia desaparece e o gráfico perde o sentido. 'Ensino médio' aparece antes de 'Fundamental', e 'Pós-graduação' antes de 'Superior'.

A diferença é evidente. No primeiro gráfico, o leitor enxerga imediatamente a distribuição da população por grau de instrução — a concentração no ensino médio, a queda acentuada no superior incompleto. No segundo, as categorias estão embaralhadas e a leitura se perde. Para dados nominais, como os países do gráfico anterior, qualquer ordem serve. Para dados ordinais, **a ordem é parte da informação**.

A mediana como medida central

Para dados ordinais, a **mediana** é a medida de tendência central adequada — ela identifica o nível "central" da distribuição. A **moda** (o nível mais frequente) também é válida. A **média**, porém, não tem sentido: requer distâncias iguais entre os níveis, algo que dados ordinais não garantem (6).

Tabela 5: Medida de tendência central para o biotipo — a mediana identifica o nível central.

n	Moda	Mediana
391	medium	medium

Os níveis são definidos pelo pesquisador

Uma das ideias mais importantes sobre dados categóricos — e uma extensão direta da lição de Graunt — é que **os níveis de uma variável categórica são uma decisão do pesquisador**. A mesma realidade pode ser categorizada de formas diferentes, e essa decisão tem consequências diretas para a análise.

Considere a variável “escolaridade”. Um pesquisador pode defini-la com três níveis (fundamental, médio, superior), com cinco (fundamental incompleto, fundamental completo, médio, superior incompleto, superior completo) ou até com categorias mais detalhadas que incluam pós-graduação. Cada escolha gera uma variável diferente — com granularidade diferente e poder de discriminação diferente.

Tabela 6: A mesma variável, diferentes níveis — a granularidade é decisão do pesquisador.

Variável	Versão	Níveis
Escolaridade	3 níveis	Fundamental, Médio, Superior
Escolaridade	5 níveis	Fund. incompleto, Fund. completo, Médio, Sup. incompleto, Sup. completo
Escolaridade	7 níveis	Inclui pós-graduação (mestrado, doutorado)
IMC	2 níveis	Normal, Excesso de peso
IMC	4 níveis	Baixo peso, Normal, Sobrepeso, Obesidade
IMC	6 níveis	Inclui graus de obesidade (I, II, III)
Dor	2 níveis	Sim, Não
Dor	4 níveis	Ausente, Leve, Moderada, Intensa
Dor	11 níveis	Escala numérica 0–10 (tratada como ordinal)

Mais níveis nem sempre é melhor

Aumentar o número de níveis aumenta a granularidade, mas pode **reduzir o tamanho amostral em cada nível**, dificultando comparações estatísticas. A escolha ideal equilibra precisão clínica com viabilidade analítica. Uma regra prática: cada nível deve conter casos suficientes para que as frequências sejam interpretáveis.

Tabelas de contingência: cruzando categorias

Quando queremos analisar a **associação** entre duas variáveis categóricas, usamos uma **tabela de contingência** (ou tabela cruzada). Cada célula mostra a frequência de sujeitos que pertencem simultaneamente a uma categoria de cada variável.

Tabela 7: Tabela de contingência — sexo vs. biotipo. Cada célula é uma combinação de categorias.

Sexo	Small	Medium	Large	Total
female	69	116	42	227
male	35	68	61	164

A tabela de contingência é o ponto de partida para testes de associação como o **qui-quadrado** (χ^2) e o **teste exato de Fisher** — os equivalentes categóricos do teste *t* e da correlação para dados numéricos.

A tabela de contingência resume os dados numericamente, mas nem sempre permite perceber de imediato os padrões de distribuição. Por isso, é útil complementar a tabela com um gráfico. No gráfico de barras empilhadas proporcionais, cada barra corresponde a um sexo, e cada segmento indica a proporção de indivíduos classificados em cada biotipo. Esse tipo de visualização ajuda a comparar se a distribuição dos biotipos é semelhante ou diferente entre os grupos.

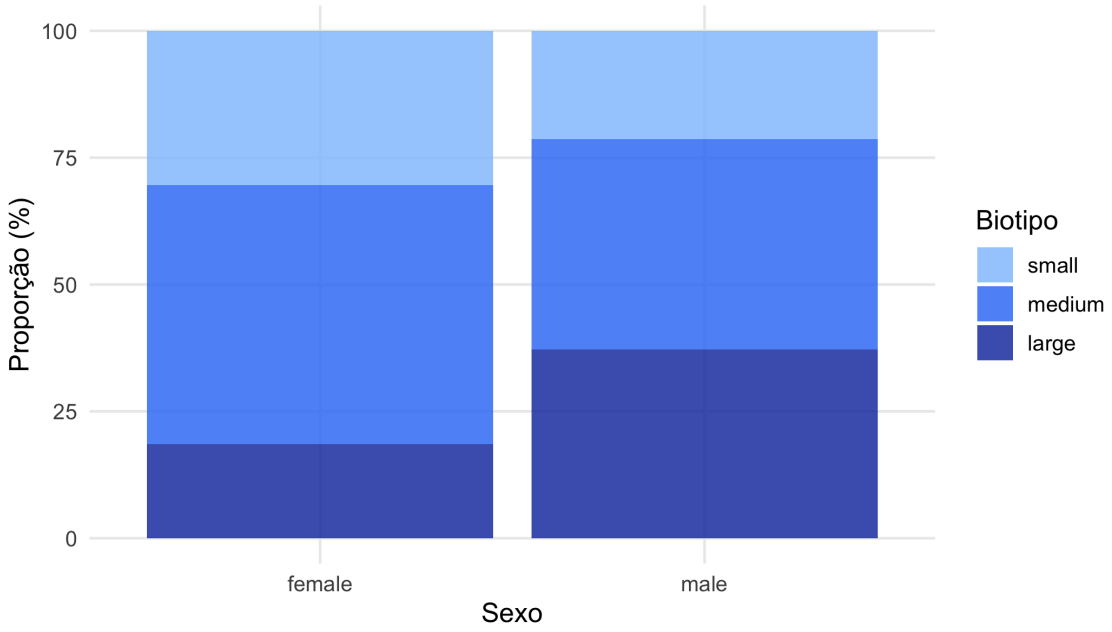

Figura 4: Distribuição do biotipo por sexo — barras empilhadas proporcionais.

Se as proporções dos segmentos forem parecidas entre as barras, isso sugere distribuições semelhantes entre os sexos. Se houver diferenças visíveis no tamanho relativo dos segmentos, isso pode indicar uma possível associação entre as variáveis, a ser formalmente avaliada por testes como o qui-quadrado ou o teste exato de Fisher.

O perigo dos números que parecem numéricos

Um dos erros mais comuns em pesquisa é tratar variáveis categóricas ordinais **como se fossem numéricas** — simplesmente porque os níveis foram codificados com números. Se atribuímos 1 = leve, 2 = moderado, 3 = grave a uma escala de dor, o software aceita calcular a “média = 2,3” sem nenhum protesto. Mas essa média **não tem significado clínico**: ela pressupõe que a distância entre “leve” e “moderado” é a mesma que entre “moderado” e “grave” — o que raramente é verdade (7,8).

Tabela 8: O mesmo dado ordinal codificado de três formas diferentes — note como a ‘média’ muda.

Nível de dor	Codificação A	Codificação B	Codificação C
Leve	1	1	1
Moderado	2	2	3
Grave	3	5	10

Se tivermos 3 pacientes com dor leve, 5 com moderada e 2 com grave, a “média” será 1,9 na codificação A, 2,3 na B e 4,1 na C — três respostas diferentes para os mesmos dados. A média é um artefato da codificação, não uma propriedade dos dados.

> ⚠️ **E a escala de Likert?**
>
> O exemplo mais debatido desse dilema é a **escala de Likert** — aquela em que o respondente marca seu grau de concordância de “discordo totalmente” (1) a “concordo totalmente” (5). Pode-se calcular a média de respostas Likert? Existem argumentos apaixonados dos dois lados. Esse debate — que envolve as contribuições de Jamieson, Norman, Carifio e outros — é o tema central do **Capítulo 6** (9).

Como reportar dados categóricos

A forma padrão de reportar dados categóricos em artigos científicos é por meio de **frequências absolutas e relativas** (n e %), organizadas em tabelas:

Tabela 9: Modelo de tabela descritiva para dados categóricos — formato padrão em artigos científicos.

Variável	Nível	n	%
Sexo	female	234	58.1
Sexo	male	169	41.9
Biotipo	small	104	26.6
Biotipo	medium	184	47.1
Biotipo	large	103	26.3
Cidade	Buckingham	200	49.6
Cidade	Louisa	203	50.4

Sempre reporte n e %

Reportar apenas a porcentagem sem o n absoluto dificulta a interpretação — 50% pode significar 5 de 10 ou 500 de 1000. A convenção é apresentar ambos: **n (%)**, como em “feminino: 234 (58,1%)”. Isso permite ao leitor avaliar tanto a proporção quanto a precisão da estimativa.

Nominal vs. ordinal: resumo comparativo

Tabela 10: Comparação entre variáveis nominais e ordinais — as diferenças que importam na prática.

Aspecto	Nominal	Ordinal
Ordem entre níveis	Não existe	Existe (hierarquia natural)
Medida de centro	Moda	Mediana
Frequência acumulada	Sem sentido	Faz sentido (% acumulado)
Codificação numérica	Rótulos arbitrários (0/1)	Reflete a ordem, mas distâncias não garantidas
Gráfico	Barras (qualquer ordem)	Barras (ordem fixa)
Teste de associação	Qui-quadrado, Fisher	Mann-Whitney, Kruskal-Wallis
Exemplo do estudo	Sexo (female, male)	Biotipo (small < medium < large)

Resumo do capítulo

Tabela 11: Resumo — dados categóricos em pesquisa em saúde.

Conceito	Definição	Exemplo do estudo
Variáveis nominais	Categorias sem ordem; rótulos intercambiáveis	Sexo, tipo sanguíneo, cidade
Variáveis ordinais	Categorias com hierarquia; ordem sem distâncias iguais	Biotipo, estadiamento de câncer, escala de dor
Variáveis binárias	Caso especial com exatamente dois níveis (sim/não, 0/1)	Sexo (female/male), óbito (sim/não)
Níveis		

Conceito	Definição	Exemplo do estudo
	As categorias possíveis, definidas pelo pesquisador antes da coleta	Biotipo: small, medium, large — definidos pelo protocolo
Tabela de frequência	Frequência absoluta (n) e relativa (%) por nível	Female: 234 (58,1%); Male: 169 (41,9%)
Tabela de contingência	Cruzamento de duas variáveis categóricas (linha × coluna)	Sexo × biotipo: quantos homens são 'large'?
Gráfico de barras	Representação visual adequada para dados categóricos	Barras verticais com proporção (%) no eixo y

ⓘ **Próximos passos**

Este capítulo apresentou os dados categóricos — nominais, ordinais e suas propriedades. No próximo capítulo, enfrentaremos os **casos especiais**: variáveis que desafiam a classificação simples, como a escala de Likert, o IMC (contínuo que vira categórico) e outros limites entre o numérico e o categórico.

Referências

1.

Graunt J. Natural and Political Observations Mentioned in a Following Index, and Made upon the Bills of Mortality. London: Tho. Roycroft for John Martin, James Allestry, and Tho. Dicas; 1662.

2. Stigler SM. The History of Statistics: The Measurement of Uncertainty before 1900. Cambridge, MA: Harvard University Press; 1986.
3. Stigler SM. Statistics on the Table: The History of Statistical Concepts and Methods. Cambridge, MA: Harvard University Press; 1999.
4. Agresti A. Statistical Methods for the Social Sciences. 5.ª ed. Boston: Pearson; 2018.
5. Stevens SS. On the Theory of Scales of Measurement. Science. 1946;103(2684):677–80.
6. Siegel S, Castellan Jr. NJ. Nonparametric Statistics for the Behavioral Sciences. 2.ª ed. New York: McGraw-Hill; 1988.
7. Velleman PF, Wilkinson L. Nominal, Ordinal, Interval, and Ratio Typologies Are Misleading. The American Statistician. 1993;47(1):65–72.
8. Hand DJ. Measurement Theory and Practice: The World through Quantification. London: Arnold Publishers; 2004.
9. Likert R. A Technique for the Measurement of Attitudes. Archives of Psychology. 1932;22(140):5–55.

Casos Especiais

Quando o tipo de dado muda: Likert, contexto e a mesma variável com duas identidades

A história

Em 1932, o psicólogo americano Rensis Likert (pronuncia-se “LICK-ert”, não “LIE-kert”) publicou sua tese de doutorado nos *Archives of Psychology*: *A Technique for the Measurement of Attitudes*. O problema que o motivava era antigo: como medir algo tão subjetivo quanto uma atitude — a favorabilidade de uma pessoa em relação a uma política, um grupo social, uma instituição? (1).

A solução era elegante. Em vez de perguntas de sim/não, Likert propôs que os respondentes indicassem seu grau de concordância com uma série de afirmações, numa escala de cinco pontos: *discordo totalmente*, *discordo*, *indeciso*, *concordo*, *concordo totalmente*. Cada resposta recebia um valor de 1 a 5, e os valores dos itens individuais eram somados num escore total que representava a atitude do sujeito. A técnica era simples, confiável e — crucialmente — produzia números. Tornou-se rapidamente uma das mais utilizadas em ciências sociais e da saúde. Mas a natureza dos números que ela produz gerou um debate longo, que só nas últimas décadas encontrou uma resolução prática.

Escala de Likert: item vs. escala

Para entender a escala de Likert é preciso primeiro distinguir dois conceitos que são facilmente confundidos:

Um **item Likert** é uma afirmação isolada à qual o respondente reage numa escala de concordância. Exemplo: “Eu me sinto satisfeito com o atendimento recebido” — de 1 (*discordo totalmente*) a 5 (*concordo totalmente*).

O **escore da escala Likert** é a **soma** (ou média) de múltiplos itens Likert que medem o mesmo constructo. Se um questionário de satisfação tem 10 itens, cada um de 1 a 5, o escore total varia de 10 a 50.

A classificação dos dados Likert gerou um dos debates mais longos da metodologia quantitativa. De um lado, a posição ordinalista: cada item Likert é ordinal, os números representam categorias ordenadas, e a distância entre “discordo” e “indeciso” não é necessariamente igual à distância entre “concordo” e “concordo totalmente”. Logo, média e desvio-padrão não seriam apropriados — o correto seria usar mediana, moda e testes não paramétricos (2).

Do outro lado, estudos de simulação acumulados desde os anos 1930 mostraram que testes paramétricos como ANOVA e correlação de Pearson são extraordinariamente robustos a violações dessas suposições. Pearson (1931) já demonstrava que a ANOVA funcionava com distribuições assimétricas e amostras de 4 a 10. Décadas depois, Havlicek e Peterson (1976) testaram correlações de Pearson com distribuições normais, retangulares e ordinais, com amostras de 5 a 60, e concluíram que o coeficiente de Pearson é “rather insensitive to extreme violations of the basic assumptions of normality and the type of scale” (3).

A explicação teórica é simples: a suposição de normalidade dos testes paramétricos se aplica à distribuição das **médias**, não dos dados individuais. Pelo Teorema Central do Limite, com amostras maiores que 5 ou 10 por grupo, as médias se distribuem de forma aproximadamente normal independente da distribuição original (3).

O consenso atual

Hoje, a questão está resolvida na prática. O consenso se apoia em dois pontos (3–5):

1. Um **item** Likert individual é ordinal. A mediana e as frequências são a forma mais honesta de descrevê-lo.

2. O **score tota da escala** Likert composta (soma de múltiplos itens) se comporta de forma aproximadamente contínua — e o uso de média, desvio-padrão e testes paramétricos é adequado. Isso é especialmente claro quando a escala tem oito ou mais itens (4).

Item vs. escala

Um **item** Likert (uma pergunta) é ordinal. O **escore total da escala** Likert (a soma de vários itens) se comporta de forma aproximadamente contínua. A confusão entre os dois é a principal fonte de mal-entendidos sobre o tema.

Tabela 1: Item Likert vs. escala Likert — a distinção central.

Aspecto	Item Likert (individual)	Escala Likert (composta)
O que é	Uma afirmação isolada	Soma/média de múltiplos itens
Valores possíveis	1, 2, 3, 4, 5 (poucos valores discretos)	10 a 50 (ou 1,0 a 5,0 como média)
Natureza	Categórica ordinal	Tratada como numérica na prática
Média faz sentido?	Não — poucos valores, distâncias desiguais	Sim — muitos valores, TLC se aplica
Distribuição	Discreta, frequentemente assimétrica	Tende a aproximar-se da normal (TLC)
Estatística descritiva	Moda, mediana, frequências	Média, desvio-padrão
Exemplo	'Eu me sinto seguro no meu bairro' → 4	Escore de satisfação = 38 (soma de 10 itens)

TLC = **Teorema do Limite Central**: quando somamos muitas variáveis independentes, a distribuição da soma tende a se aproximar da normal — mesmo que as variáveis originais não sejam normais. É por isso que escalas compostas (soma de vários itens) se comportam de forma mais “bem-comportada” que itens isolados.

Visualizando a diferença com dados simulados

Para tornar a distinção concreta, vamos simular um cenário simples: 200 sujeitos respondem a um item Likert de satisfação (1 a 5). O que muda quando analisamos o item como ordinal vs. como numérico?

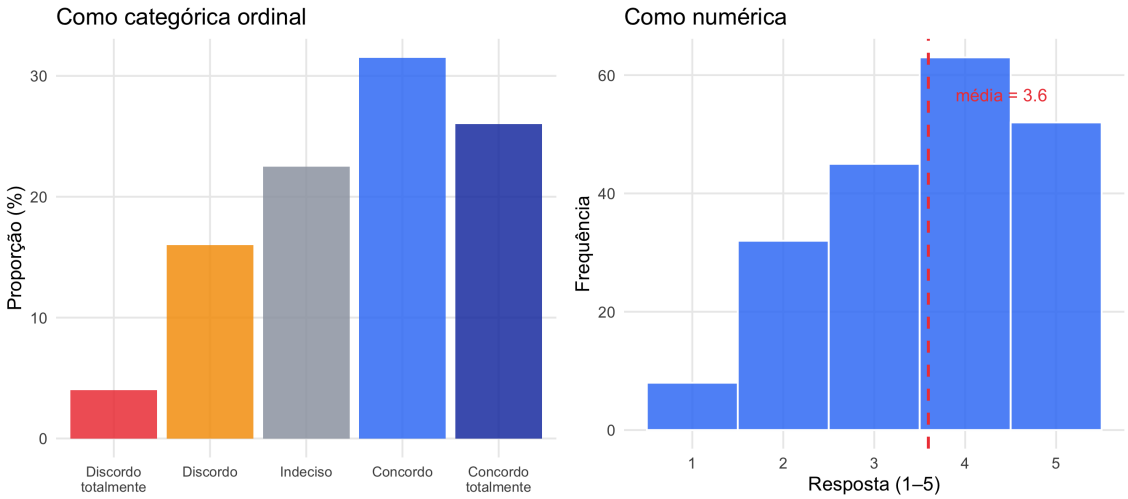

Figura 1: O mesmo item Likert visto de duas formas: como frequência de categorias (esquerda) e como distribuição numérica (direita).

Tabela 2: O mesmo dado analisado de duas formas — as conclusões são semelhantes, mas a linguagem muda.

Abordagem	Medida de centro	Interpretação	Teste de comparação
Como ordinal (não paramétrica)	Mediana = 4 (Concordo); Moda = 4 (Concordo)	A maioria concorda ou concorda totalmente	Mann-Whitney, Kruskal-Wallis
Como numérica (paramétrica)	Média = 3.6 ± 1.15	Em média, os respondentes tendem a concordar	Teste t, ANOVA

Na prática, as duas abordagens frequentemente levam à mesma conclusão (3). A diferença está na **precisão da linguagem**: dizer “a mediana é 4 (concordo)” é mais fiel à natureza ordinal do dado do que dizer “a média é 3,48”.

Recomendação prática

Na prática, a orientação pode ser resumida assim:

Tabela 3: Recomendação prática — como tratar dados Likert dependendo do contexto.

Situação	Recomendação	Justificativa
Item individual (1 a 5 ou 1 a 7)	Trate como ordinal: reporte mediana, moda e frequências; use testes não paramétricos	Poucos valores possíveis; distâncias entre níveis não garantidas
Escala composta (soma/média de ≥ 5 itens)	Pode tratar como numérica: reporte média ± DP; testes paramétricos são válidos	Muitos valores possíveis; TLC se aplica; décadas de simulações confirmam robustez
Amostra pequena (n < 30) com item individual	Sempre trate como ordinal — a robustez paramétrica depende de n suficiente	Sem n suficiente, o TLC não garante normalidade da média amostral
Apresentação descritiva em artigo	Reporte frequências por nível (%) E a mediana — mesmo que use média para análise	A distribuição de frequências é a descrição mais fiel dos dados ordinais

> ⓘ **Na dúvida, seja transparente**
>
> Reporte as frequências por nível e a mediana. Se usar a média para análise, justifique a escolha. Assim o leitor pode avaliar os dados independentemente da abordagem estatística escolhida (3,5).

A mesma variável, dois tipos

A escala de Likert ilustra um fenômeno mais geral: **a mesma informação pode ser coletada como numérica ou como categórica**. A decisão é do pesquisador — e essa decisão tem consequências diretas para a análise.

Tabela 4: A mesma realidade, dois tipos de dado — a decisão é metodológica, não da natureza.

Variável	Como numérica	Como categórica	O que se perde na categorização
Idade	47 anos	Adulto (30–59 anos)	Magnitude exata
Peso	82,3 kg	Sobrepeso (IMC 25–29,9)	Magnitude exata

Variável	Como numérica	Como categórica	O que se perde na categorização
Pressão arterial	138 mmHg	Hipertenso estágio 1	Magnitude exata
Glicemia	112 mg/dL	Pré-diabético	Magnitude exata
Dor	Escala visual analógica: 7,2 cm	Dor moderada	Precisão contínua
Escolaridade	16 anos de estudo	Ensino superior completo	Magnitude exata

A passagem de numérico para categórico é sempre possível — basta definir pontos de corte. Mas o caminho inverso é impossível: uma vez que registramos “hipertenso estágio 1”, não podemos recuperar se a pressão era 140, 152 ou 159 mmHg. A categorização é uma via de mão única, e Altman e Royston demonstram que dicotomizar uma variável contínua pela mediana reduz o poder estatístico tanto quanto descartar um terço dos dados (6).

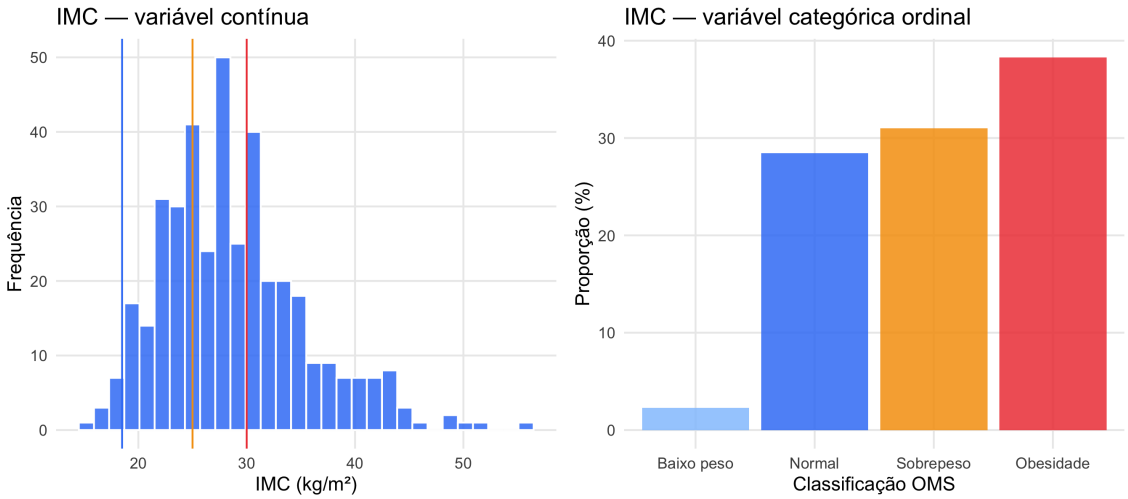

Figura 2: O IMC tem duas vidas: como variável contínua (histograma) e como categórica ordinal (barras).

O caso do IMC é paradigmático. O valor bruto (27,4 kg/m²) é uma variável contínua de razão — permite média, desvio-padrão e todas as operações aritméticas. Mas na prática clínica, é quase sempre apresentado em **categorias da OMS** (baixo peso, normal, sobrepeso, obesidade), tornando-se uma variável ordinal. A mesma informação, dois tipos de dado — e a escolha depende do objetivo: a versão contínua é

mais poderosa estatisticamente; a categórica é mais comunicável clinicamente.

> ⓘ **A regra de ouro**
>
> Sempre que possível, **colete e armazene os dados na forma mais detalhada** (numérica). Categorizar depois é fácil; recuperar a precisão perdida é impossível. Registre a pressão como 142 mmHg, não como “hipertenso” — você sempre pode criar a categoria depois, mas nunca poderá desfazer a perda (6,7).

Outros casos especiais

A escala de Likert não é o único caso em que a classificação de uma variável desafia as categorias simples. Outros exemplos frequentes em pesquisa em saúde:

Escolaridade: ordinal ou numérica?

A escolaridade pode ser registrada como **anos de estudo** (variável numérica discreta: 0, 1, 2, …, 20) ou como **nível de escolaridade** (variável categórica ordinal: fundamental, médio, superior). No IBGE, a classificação oficial é ordinal — mas muitos estudos epidemiológicos usam “anos de estudo” como proxy numérica, permitindo regressão linear em vez de modelos ordinais.

Escala visual analógica de dor (EVA)

O paciente marca um ponto numa linha de 10 cm. O valor lido — 4,7 cm — é contínuo. Mas quando transformamos em categorias (0 = sem dor, 1–3 = leve, 4–6 = moderada, 7–10 = intensa), a variável se torna ordinal. Mesmo o valor bruto levanta questões: a distância entre 2 e 4 é a mesma experiência de dor que entre 6 e 8? A escala pode ser **contínua na régua** sem ser **intervalar na experiência**.

Variáveis cíclicas

Algumas variáveis numéricas não obedecem à lógica linear. O **horário** (0h a 24h) é numérico, mas a diferença entre 23h e 1h não é 22 horas — é 2 horas. O **mês de nascimento** (1 a 12) é numérico, mas dezembro e

janeiro são adjacentes, não distantes. Variáveis cíclicas exigem métodos específicos (estatística circular) e são frequentemente tratadas de forma inadequada quando jogadas numa regressão linear convencional (8).

Variáveis truncadas e censuradas

Na pesquisa em saúde, variáveis numéricas frequentemente têm **limites de detecção**. Um exame de carga viral que reporta "< 20 cópias/mL" não informa o valor exato — apenas que está abaixo do limite de detecção. Esses dados **censurados** não podem ser tratados como zero nem como o valor do limite; exigem métodos estatísticos específicos (como a regressão de Tobit ou métodos de sobrevida) que levem em conta a informação parcial.

Tabela 5: Exemplos

Variável	Versão numérica	Versão categórica	Desafio
IMC	27,4 kg/m²	Sobrepeso (OMS)	Perda de poder ao categorizar
Escolaridade	14 anos de estudo	Ensino médio completo	Proxy numérica comum mas imprecisa
Dor (EVA)	4,7 cm	Dor moderada	Contínua na régua, ordinal na experiência?
Horário do evento	23:15	Período noturno	Variável cíclica — diferenças lineares falham
Carga viral	> 20 cópias/mL	Indetectável vs. detectável	Censura à esquerda — valor exato desconhecido
Likert (item)	4 (concordo)	Concordo	Ordinal, mas tratada como numérica por muitos
Likert (escala)	38 pontos (soma de 10 itens)	Alta satisfação	Composta — comporta-se como intervalar

A lição dos casos especiais

Os exemplos deste capítulo convergem para uma mesma lição: a classificação de uma variável **não é uma propriedade intrínseca do fenômeno** — é o resultado de decisões sobre como medir, registrar e

analisar. A idade é contínua por natureza, mas pode ser coletada como discreta (anos inteiros) ou categórica (faixa etária). O IMC é contínuo, mas a prática clínica o transforma em ordinal. A escala de Likert muda de natureza dependendo de como é agregada — um item é ordinal, uma escala composta se comporta como contínua.

Essa fluidez não é um defeito do sistema de classificação de Stevens — é uma característica da realidade. As escalas de medida são **modelos**, não leis da natureza (8,9). O pesquisador deve escolher o modelo que melhor serve ao objetivo da análise, documentar essa escolha e estar preparado para justificá-la.

> ⚠ **Documente suas decisões**
>
> Em qualquer artigo ou relatório, explicite: (1) como a variável foi medida originalmente, (2) se e como foi categorizada, e (3) por que essa classificação foi escolhida. Essa transparência permite que revisores e leitores avaliem se a análise é coerente com a natureza dos dados — e é exatamente o que diretrizes como o STROBE recomendam (10).

Resumo do capítulo

Tabela 6: Resumo — casos especiais na classificação de variáveis.

Conceito	Definição	Recomendação prática
A mesma variável, dois tipos	O pesquisador decide se coleta/analisa como numérica ou categórica	Colete na forma mais detalhada possível; categorize depois se necessário
Item Likert	Afirmação isolada com resposta de 1 a 5 (ou 7) — ordinal	Reporte frequências por nível e mediana
Escala Likert (composta)	Soma ou média de múltiplos itens — comporta-se como contínua	Média ± DP e testes paramétricos são adequados
Debate Likert (resolvido)	Item = ordinal (consenso); escala composta = testes paramétricos são robustos	Seja transparente: reporte frequências E mediana, mesmo que use média
IMC: dupla identidade	Contínuo (kg/m²) na coleta; ordinal (OMS) na prática clínica	

Conceito	Definição	Recomendação prática
		Mantenha contínuo para análise; categorize para comunicação clínica
Variáveis cíclicas	Valores numéricos sem linearidade (horário, mês) — exigem estatística circular	Não use média aritmética; considere estatística circular
Dados censurados	Valor exato desconhecido (< limite de detecção) — exigem métodos especiais	Não substitua por zero nem pelo limite; use métodos de censura

> ⓘ **Próximos passos**
>
> Este capítulo explorou os casos em que a classificação de variáveis desafia as categorias simples. No próximo capítulo vamos aprender a **organizá-los** — como estruturar planilhas para que os dados possam ser analisados de forma eficiente e reproduzível.

Referências

1. Likert R. A Technique for the Measurement of Attitudes. Archives of Psychology. 1932;22(140):5–55.
2. Jamieson S. Likert Scales: How to (Ab)Use Them. Medical Education. 2004;38(12):1217–8.
3. Norman G. Likert Scales, Levels of Measurement and the «Laws» of Statistics. Advances in Health Sciences Education. 2010;15(5):625–32.
4. Carifio J, Perla R. Resolving the 50-Year Debate around Using and Misusing Likert Scales. Medical Education. 2008;42(12):1150–2.
5. Sullivan GM, Artino Jr. AR. Analyzing and Interpreting Data from Likert-type Scales. Journal of Graduate Medical Education. 2013;5(4):541–2.
6. Altman DG, Royston P. The Cost of Dichotomising Continuous Variables. BMJ (Clinical research ed). 2006;332(7549):1080.
7. Agresti A. Statistical Methods for the Social Sciences. 5.ª ed. Boston: Pearson; 2018.
8. Hand DJ. Measurement Theory and Practice: The World through Quantification. London: Arnold Publishers; 2004.
9. Velleman PF, Wilkinson L. Nominal, Ordinal, Interval, and Ratio Typologies Are Misleading. The American Statistician. 1993;47(1):65–72.
10.

Vandenbroucke JP, von Elm E, Altman DG, Gøtzsche PC, Mulrow CD, Pocock SJ, et al. Strengthening the Reporting of Observational Studies in Epidemiology (STROBE): Explanation and Elaboration. Annals of Internal Medicine. 2007;147(8):W-163-W-194.

Organizando Dados em Planilhas

Boas práticas de organização de dados

O arquivos de dados de uma pesquisa

Toda pesquisa gera um conjunto de dados que precisam ser armazenados de alguma forma. Via de regra, são armazenados em formato de tabelas, nas quais cada variável é representada por uma coluna e cada participante da pesquisa por uma linha. A primeira linha contém os nomes das variáveis; as linhas seguintes são os dados de cada participante. O banco de dados que usamos neste livro — `pacientes.csv` — segue exatamente esse formato:

Tabela 1: Primeiras linhas do banco de dados pacientes.csv — cada linha é um paciente, cada coluna é uma variável.

ID	Idade	Sexo	Colesterol	Glicose	Cidade
1000	46	female	203	82	Buckingham
1001	29	female	165	97	Buckingham
1002	58	female	228	92	Buckingham
1003	67	male	78	93	Buckingham

Existem vários formatos para armazenar tabelas como essa. O mais comum é o formato de planilhas eletrônicas: o Excel usa arquivos `.xlsx`, o Numbers da Apple usa `.numbers`, o LibreOffice usa `.ods`. O problema é que cada formato só é plenamente legível pelo software que o criou.

Um dos formatos mais comuns para armazenar os dados de uma pesquisa é o **csv** (*comma-separated values* — valores separados por vírgula), com extensão `.csv`. Um arquivo **csv** é texto puro: nada mais que valores separados por vírgulas, um participante por linha. Se abrirmos o arquivo `pacientes.csv` num editor de texto simples, como o Bloco de Notas do Windows ou o TextEdit do Mac, vemos apenas isso:

```
id,colesterol,glicose,hdl,idade,sexo,altura,peso,cidade
1000,203,82,56,46,female,157.48,54.88,Buckingham
1001,165,97,24,29,female,162.56,98.88,Buckingham
1002,228,92,37,58,female,154.94,116.12,Buckingham
1003,78,93,12,67,male,170.18,53.98,Buckingham
```

Sem formatação, sem cores, sem fórmulas escondidas — apenas dados. Qualquer software lê esse formato: R, Python, SPSS, Stata, Excel, em qualquer sistema operacional, sem depender de versão ou licença. É o formato de intercâmbio universal para dados de pesquisa.

A simplicidade do CSV é a sua maior força — e também a sua limitação. Um arquivo CSV é apenas texto: linhas e colunas separadas por um delimitador. Qualquer software consegue abri-lo, qualquer linguagem consegue lê-lo. Mas essa simplicidade tem um custo: o CSV não carrega nenhuma informação sobre o significado dos dados. Ele não sabe que a coluna `sexo` contém valores `1` e `2` que representam “masculino” e “feminino”. Não sabe que `glicose` é medida em mg/dL. Não sabe quais valores devem ser tratados como ausentes. O CSV guarda os dados, mas não os metadados.

Formatos de softwares estatísticos como `.sav` (SPSS) e `.dta` (Stata) funcionam de maneira diferente. Além dos dados em si, esses arquivos armazenam **metadados**: o rótulo descritivo de cada variável (por exemplo, `"Glicemia de jejum (mg/dL)"`), os rótulos de cada valor categórico (`1 = masculino`, `2 = feminino`), os valores definidos como ausentes e até o formato de exibição. Em outras palavras, o dicionário de variáveis já vem embutido no arquivo — dados e documentação viajam juntos.

Para importar esses formatos mais ricos sem perder os metadados, o R oferece o pacote `haven` e o Python oferece o pacote `pyreadstat`. Ambos leem os dados e os metadados de uma só vez: ao abrir um `.sav` com `haven::read_sav()`, cada coluna já chega com seu rótulo e seus valores codificados. Isso evita aquele passo manual de consultar um dicionário separado para entender o que cada variável significa.

Nada disso significa que você deva abandonar o CSV — ele continua sendo o formato mais comum para armazenamento. Mas é importante saber que, ao escolher CSV, você está abrindo mão dos metadados. O dicionário de variáveis precisa existir em algum lugar — só não vai ser dentro do arquivo.

> ⓘ **Vírgulas, ponto e vírgula e decimais**
>
> O nome **csv** vem de *comma-separated values* — valores separados por vírgula. Mas nem todo CSV usa vírgula como separador. Na prática, existem três separadores comuns:
>
> - **Vírgula** (`,`): o padrão original, usado em países de língua inglesa.
> - **Ponto e vírgula** (`;`): comum no Brasil e em outros países que usam vírgula como separador decimal.
> - **Tabulação** (`Tab`): usado em arquivos `.tsv`, mas às vezes com extensão `.csv`.
>
> O motivo dessa variação é o **separador decimal**. Em inglês, o número três e meio se escreve `3.5` (com ponto). Em português, se escreve `3,5` (com vírgula). Se o arquivo usasse vírgula como separador decimal *e* como separador de colunas, o resultado seria uma confusão. Por isso, quando os decimais usam vírgula, o separador de colunas precisa ser outro — geralmente ponto e vírgula. Nesse exemplo abaixo a vírgula representa a separador de decimais e o ponto e virgula o separador dos valores
>
> ```
> id;colesterol;glicose
> 1000;203,5;82,3
> ```
>
> Antes de importar um `csv`, abra o arquivo em um editor de texto simples (Bloco de Notas, TextEdit) e verifique: qual é o separador de colunas? E qual é o separador decimal? No R, a função `read.csv()` espera vírgula e ponto decimal; `read.csv2()` espera ponto e vírgula e vírgula decimal.

A história

Em 2010, dois economistas de Harvard — Carmen Reinhart e Kenneth Rogoff — publicaram um artigo influente intitulado *Growth in a Time of Debt*. A conclusão era contundente: países com dívida pública acima de 90% do PIB apresentavam crescimento econômico **negativo** (média de

−0,1%). O artigo tornou-se rapidamente uma das referências mais citadas no debate global sobre austeridade. Foi invocado no orçamento federal dos Estados Unidos, nos cortes de gastos do Reino Unido e nas políticas de austeridade da zona do euro após a crise de 2008 (1).

Em abril de 2013, Thomas Herndon — um aluno de mestrado da Universidade de Massachusetts Amherst — tentou replicar os resultados como exercício de aula. Não conseguiu. Quando Reinhart e Rogoff gentilmente compartilharam sua planilha original do Excel, Herndon descobriu o que se tornaria um dos escândalos metodológicos mais célebres da economia moderna (2).

O problema tinha três camadas. Primeiro, ao calcular a média de crescimento para a categoria “>90% de dívida”, a fórmula do Excel selecionava as células das linhas 30 a 44 em vez de 30 a 49 — **excluindo acidentalmente cinco países** (Austrália, Áustria, Bélgica, Canadá e Dinamarca) simplesmente porque estavam no topo da lista em ordem alfabética. Segundo, Reinhart e Rogoff haviam excluído deliberadamente dados da Austrália, do Canadá e da Nova Zelândia no pós-guerra sem justificativa explícita — países que, aliás, cresceram durante períodos de dívida alta. Terceiro, a metodologia de ponderação tratava cada país como uma única observação, independentemente de quantos anos aparecia na categoria — assim, os 19 anos do Reino Unido tinham o mesmo peso que o único ano da Nova Zelândia (que, convenientemente, registrou crescimento negativo naquele ano) (2).

Quando Herndon corrigiu os três problemas, a média de crescimento para países com dívida acima de 90% do PIB não era −0,1% — era **+2,2%**. A conclusão central do artigo original evaporava.

> ⚠ **A lição de Reinhart-Rogoff**
>
> O erro não estava na teoria econômica, nem na qualidade dos dados. Estava na **planilha**. Uma fórmula que não selecionou todas as células. Dados organizados de forma que o erro fosse invisível. Nenhuma verificação automática. O episódio demonstra que a organização dos dados não é um detalhe técnico — é uma **decisão metodológica** com consequências reais.

A regra fundamental

O erro de Reinhart e Rogoff não foi um acidente isolado — foi consequência de usar a planilha para algo que ela não deveria fazer. A fórmula que excluiu cinco países era invisível: nenhum colega, nenhum revisor e nenhum leitor poderia ter notado o problema olhando para os resultados. O erro só apareceu quando alguém abriu a planilha e inspecionou célula por célula.

A lição é direta: **planilhas servem para armazenar dados, não para analisar**. A análise — cálculos, transformações, modelos, gráficos — deve ser feita em software estatístico com código documentado: R, Python, SPSS, Stata ou qualquer ferramenta em que cada passo fique registrado e seja reproduzível. Num script em R ou Python, o erro de Reinhart e Rogoff seria uma linha de código legível, revisável e rastreável — não uma fórmula escondida numa célula.

O formato que faz a ponte entre a planilha e o software de análise é o **CSV** (*comma-separated values* — valores separados por vírgula). Um arquivo `.csv` é texto puro: qualquer software lê, em qualquer sistema operacional, sem depender de versão ou licença. Não tem formatação oculta, não converte nomes de genes em datas, não esconde fórmulas em células.

> ⓘ **Planilha = armazenamento. Código = análise.**
>
> Use o Excel (ou Google Sheets) apenas para **organizar** os dados. Salve em formato **CSV**. Faça toda a análise em **software estatístico com código reproduzível**. Nunca use fórmulas em planilhas eletrônicas para gerar resultados de pesquisa.

Por que a organização importa

Se a planilha é apenas o lugar onde os dados ficam guardados, a forma como os organizamos determina se o software de análise vai conseguir lê-los sem problemas. Pesquisadores passam até 80% do tempo de uma análise com **limpeza e reorganização** de dados — quase sempre

porque os dados foram organizados para o olho humano, não para o computador (3,4).

A boa notícia é que existem princípios claros, baseados em décadas de experiência, que tornam qualquer planilha mais robusta e mais fácil de importar para R, Python ou qualquer outro software. Esses princípios podem ser resumidos numa ideia central: **organize os dados para o computador, não para o olho humano**.

Tidy data: os três princípios

O conceito de *tidy data* (dados arrumados), formalizado em 2014, fornece uma estrutura simples e poderosa para organizar dados tabulares. A ideia é análoga ao conceito de terceira forma normal em bancos de dados relacionais, mas traduzida para a linguagem da estatística (3).

Dados *tidy* obedecem a três regras:

Tabela 2: Os três princípios de dados arrumados (tidy data) — simples na teoria, transformadores na prática.

Princípio	O que significa	Exemplo de violação
1. Cada variável é uma coluna	Todas as medições do mesmo atributo (ex: peso) ficam numa única coluna	Peso de homens e peso de mulheres em colunas separadas
2. Cada observação é uma linha	Todos os atributos de um mesmo sujeito (ex: paciente 1001) ficam numa única linha	Mesmo paciente em duas linhas por estar em dois centros
3. Cada tipo de unidade observacional é uma tabela	Dados de naturezas diferentes (ex: pacientes e exames) ficam em tabelas separadas	Misturar dados de pacientes e dados de hospitais na mesma tabela

O nosso banco de dados `pacientes.csv` — que vimos no início do capítulo — é um exemplo de dados *tidy*: cada linha é um paciente, cada coluna é uma variável, e há uma única tabela com um tipo de unidade observacional (pacientes).

Dados messy: os cinco problemas comuns

A maioria dos dados reais **não** é *tidy*. Os cinco problemas mais comuns, com seus remédios, são (3):

Tabela 3: Os cinco problemas mais comuns de dados 'messy' — e como corrigi-los.

Problema	Exemplo	Remédio
Cabeçalhos de coluna são valores, não nomes	Colunas 'semana_1', 'semana_2', … em vez de uma coluna 'semana' e outra 'valor'	Pivotar (pivot_longer): transformar colunas em linhas
Múltiplas variáveis em uma única coluna	Coluna 'm1524' que codifica sexo masculino + faixa etária 15–24 juntos	Separar (separate): dividir a coluna em duas variáveis
Variáveis armazenadas em linhas e colunas	Uma coluna 'elemento' com valores 'tmax' e 'tmin' que são variáveis diferentes	Pivotar para mais largo (pivot_wider): linhas viram colunas
Múltiplos tipos de unidade na mesma tabela	Dados do hospital e do paciente misturados na mesma planilha	Separar em tabelas distintas com chave de ligação (ID)
Uma unidade espalhada por múltiplas tabelas	Dados de janeiro num arquivo, fevereiro noutro, sem estrutura consistente	Empilhar (bind_rows) com estrutura padronizada

Boas práticas em planilhas

As recomendações a seguir — baseadas em experiência acumulada e erros reais — tornam qualquer planilha mais robusta, mais reproduzível e menos propensa aos tipos de erro que afundaram Reinhart e Rogoff (4).

1. Seja consistente

A primeira regra é a mais simples e a mais violada: **seja consistente**. Se a variável sexo é codificada como `female`, use sempre `female` — nunca `Female`, `fem`, `F` ou `feminino` no meio do banco. Se as datas estão em formato `YYYY-MM-DD`, mantenha esse formato em todas as células. Se

os valores ausentes são codificados como `NA`, use sempre `NA` — nunca `-999`, célula vazia ou a palavra “missing” (4).

A inconsistência é invisível para quem digita e devastadora para quem analisa. Um simples espaço extra (`male` vs. `male`) cria duas categorias diferentes para o software.

2. Escolha bons nomes de variáveis

Nomes de variáveis devem ser **curtos, significativos e legíveis por máquina**. Na prática, isso significa: sem espaços, sem acentos, sem caracteres especiais, preferencialmente em `snake_case` (4).

Tabela 4: Exemplos de nomes de variáveis — boas e más práticas.

Bom nome	Nome a evitar	Problema
peso_kg	Peso (kg)	Parênteses e espaços
pressao_sistolica	Pressão Sistólica	Acentos e maiúsculas
data_coleta	Data da Coleta	Espaços e preposição
glicose_jejum	Glicose em jejum (mg/dL)	Espaços, parênteses e unidade
sexo	Sexo do Paciente	Redundante — óbvio pelo contexto
idade_anos	Idade (em anos completos)	Parênteses e redundância

Nosso banco de dados segue essa prática: `colesterol`, `glicose`, `hdl`, `peso`, `altura`, `sistolica`, `diastolica`, `cintura`, `quadril`. Nomes curtos, sem espaços, sem acentos.

3. Datas em formato ISO

Datas devem ser registradas no formato **YYYY-MM-DD** (ISO 8601): `2024-03-15`, não `15/03/2024` nem `March 15, 2024`. Esse formato evita a confusão entre dia e mês (o que significa 03/04/2024?), é ordenável cronologicamente como texto e é reconhecido universalmente por software estatístico (4).

⚠ **Excel e datas: uma relação perigosa**

> O Excel armazena datas internamente como números (dias desde uma data de referência) e pode reformatar datas silenciosamente ao abrir um arquivo. Pior: em algumas versões, nomes de genes como *OCT4* e *MARCH1* são convertidos automaticamente em datas. Um estudo encontrou que cerca de 20% dos artigos com listas de genes em arquivos suplementares continham erros de conversão de datas (4). A recomendação é formatar a coluna como "Texto" *antes* de digitar as datas.

4. Sem células vazias

Toda célula deve conter um valor. Se o dado está ausente, use um código explícito — preferencialmente `NA`. Nunca deixe a célula vazia, porque o software não consegue distinguir entre "dado ausente" e "esqueci de preencher". Nunca use códigos numéricos como `-999` ou `0` para representar ausência, pois podem ser confundidos com valores reais (4).

5. Uma coisa por célula

Cada célula deve conter **uma única informação**. Se a posição na placa é `13-A01`, é melhor ter três colunas: `placa` = 13, `linha` = A, `coluna` = 01. Se o peso inclui unidade (`45 g`), separe em `peso` = 45 e documente a unidade no dicionário de dados (4).

6. Faça um retângulo

Os dados devem formar **um retângulo**: sujeitos nas linhas, variáveis nas colunas, uma única linha de cabeçalho com os nomes das variáveis. Sem tabelas espalhadas pela planilha, sem linhas de título mescladas, sem subtotais intercalados, sem múltiplas tabelas na mesma aba (4).

Tabela 5: O banco de dados como retângulo — a estrutura que todo software espera.

id	idade	sexo	colesterol	glicose	cidade
1000	46	female	203	82	Buckingham
1001	29	female	165	97	Buckingham
1002	58	female	228	92	Buckingham
1003	67	male	78	93	Buckingham
1005	64	male	249	90	Buckingham

7. Crie um dicionário de dados

Todo banco de dados deveria ser acompanhado de um **dicionário** (ou *codebook*) que descreva cada variável: nome, significado, unidade, tipo, valores possíveis e regras de codificação. O dicionário é um documento separado — nunca dentro da planilha de dados (4).

Tabela 6: Exemplo de dicionário de dados para o banco pacientes.csv — o 'manual de instruções' do banco.

Variável	Descrição	Tipo	Unidade	Valores
id	Identificador único do paciente	Numérica (ID)	—	1000–1402
idade	Idade em anos completos	Numérica contínua	anos	19–92
sexo	Sexo biológico	Categórica nominal	—	female, male
colesterol	Colesterol total em jejum	Numérica contínua	mg/dL	78–443
glicose	Glicemia em jejum	Numérica contínua	mg/dL	48–385
hdl	HDL-colesterol	Numérica contínua	mg/dL	12–120
peso	Peso corporal	Numérica contínua	kg	27,2–159,7
altura	Estatura	Numérica contínua	cm	130,8–195,6
biotipo	Classificação do biotipo corporal	Categórica ordinal	—	small, medium, large
sistolica	Pressão arterial sistólica	Numérica contínua	mmHg	82–250
cidade	Cidade de residência	Categórica nominal	—	Buckingham, Louisa

8. Sem cálculos no arquivo de dados brutos

Esta é a regra fundamental do capítulo aplicada ao arquivo: o arquivo de dados primário deve conter **apenas dados** — sem fórmulas, sem

médias calculadas, sem gráficos embutidos. Toda análise vai para o código (R, Python, etc.), nunca para células do Excel. O arquivo original deve ser tratado como um registro imutável — o equivalente a um caderno de laboratório (4).

9. Não use cores como dados

É tentador destacar com cores as linhas com problemas, marcar outliers em vermelho ou indicar o sexo dos pacientes com azul e rosa. Mas cores não são dados — são formatação que se perde ao exportar para CSV e que nenhum software estatístico consegue ler automaticamente. Se uma informação precisa ser registrada, crie uma **coluna** para ela (ex: `outlier` = TRUE/FALSE) (4).

10. Salve em formato CSV

Como vimos no início do capítulo, o CSV é o formato que faz a ponte entre a planilha e o software de análise. Sempre mantenha uma cópia dos dados em **CSV** (ou TSV). Esses formatos são texto puro — abertos, universais, legíveis por qualquer software e imunes às armadilhas de formatação do Excel (4).

Verificando nosso banco de dados

Vamos aplicar os princípios ao nosso próprio banco de dados e verificar se ele atende às boas práticas:

Tabela 7: Auditoria do banco pacientes.csv — verificando aderência às boas práticas.

Critério	Resultado	Status
Formato retangular?	Sim — 403 linhas × 18 colunas	OK
Uma linha por observação?	Sim — cada linha é um paciente (n = 403)	OK
Nomes sem espaços/ acentos?	Sim — todos em snake_case (ex: glicohemoglobina, time.ppn)	OK
Valores ausentes codificados?	Sim — NA usado para ausência (51 valores ausentes em 12 variáveis)	OK

Critério	Resultado	Status
Uma coisa por célula?	Sim — cada célula contém um único valor	OK
Sem cálculos embutidos?	Sim — apenas dados brutos, sem fórmulas	OK
Formato CSV?	Sim — arquivo .csv com separador vírgula	OK

> ⓘ **Um detalhe para melhorar**
>
> O nome `time.ppn` usa ponto em vez de underscore — uma convenção mista que poderia gerar inconsistência. O ideal seria `time_ppn` para manter o padrão `snake_case`. Pequenas inconsistências como essa são comuns em dados reais e ilustram por que a padronização desde o início é tão importante.

Voltando a Reinhart e Rogoff

Cada princípio deste capítulo — dados em formato retangular, nomes consistentes, CSV como formato de intercâmbio, análise em código — teria evitado ou tornado visível o erro que mudou a política econômica de países inteiros. A fórmula que excluiu cinco países não existiria se a análise estivesse em R ou Python. A exclusão de dados sem justificativa teria sido documentada num dicionário de dados. A ponderação enviesada seria transparente num script reproduzível. E o erro teria sido detectado antes da publicação se os dados e o código estivessem disponíveis para replicação — como eventualmente Thomas Herndon fez (2).

Resumo do capítulo

Tabela 8: Resumo — organização de dados em planilhas.

Conceito	Definição	Por que importa
Tidy data	Cada variável é uma coluna; cada observação é uma linha; cada unidade é uma tabela	Facilita análise, visualização e compartilhamento
Consistência		Evita categorias duplicadas e erros de parsing

Conceito	Definição	Por que importa
	Mesmo código para a mesma informação em todo o banco (NA, female, YYYY-MM-DD)	
Nomes de variáveis	Curtos, significativos, sem espaços/acentos, em snake_case	Facilita programação e reduz erros de digitação
Datas (ISO 8601)	YYYY-MM-DD — formato universal, ordenável, sem ambiguidade dia/mês	Evita confusão 03/04 = março 4 ou 3 de abril?
Células vazias	Nunca deixar vazio; usar NA para dados ausentes; nunca usar -999 ou 0	Permite distinguir ausência intencional de erro de digitação
Retângulo	Sujeitos nas linhas, variáveis nas colunas, uma única linha de cabeçalho	Todo software estatístico espera dados nesse formato
Dicionário de dados	Documento separado descrevendo cada variável: nome, tipo, unidade, valores	Permite que qualquer pessoa entenda e reproduza a análise
Dados brutos intocáveis	O arquivo primário contém apenas dados — sem fórmulas, sem gráficos, sem cores como informação	Preserva a integridade dos dados originais — como um caderno de laboratório
Formato CSV	Manter cópia em texto simples — formato aberto, universal e imune ao Excel	Garante que os dados sobrevivam a qualquer mudança de software

Próximos passos

Este capítulo apresentou como organizar dados para que sejam analisáveis e reproduzíveis. No próximo capítulo, usaremos esses dados bem organizados para criar **visualizações** — gráficos que revelam padrões, comunicam resultados e, quando mal feitos, enganam.

Referências

1. Reinhart CM, Rogoff KS. Growth in a Time of Debt. American Economic Review. 2010;100(2):573–8.
2. Herndon T, Ash M, Pollin R. Does High Public Debt Consistently Stifle Economic Growth? A Critique of Reinhart and Rogoff. Cambridge Journal of Economics. 2014;38(2):257–79.

3. Wickham H. Tidy Data. Journal of Statistical Software. 2014;59(10):1–23.
4. Broman KW, Woo KH. Data Organization in Spreadsheets. The American Statistician. 2018;72(1):2–10.

Visualizando por Tipo de Dado

Qual gráfico usar para cada tipo de variável — e por que o tipo de dado determina a escolha

A ponte entre classificação e visualização

Os capítulos anteriores estabeleceram uma base: aprendemos a classificar variáveis em numéricas (discretas e contínuas) e categóricas (nominais e ordinais), a reconhecer casos especiais e a organizar dados em planilhas. Agora, a pergunta natural é: **como visualizar esses dados?**

A resposta depende, antes de tudo, do **tipo de dado**. Uma variável numérica contínua pede um histograma ou boxplot; uma variável categórica nominal pede um gráfico de barras; o cruzamento de uma variável numérica com uma categórica pede boxplots lado a lado. Essa correspondência não é arbitrária — ela reflete a natureza das operações que fazem sentido para cada tipo de escala (1,2).

Este capítulo não pretende ser um guia completo de visualização estatística — para isso, existe o site Dos Dados aos Gráficos, que cobre em profundidade a gramática dos gráficos, cada tipo de gráfico, princípios de Tufte, pensamento crítico e ferramentas. O objetivo aqui é mais específico: mostrar como a **classificação do tipo de dado** — o tema central deste projeto — determina a escolha do gráfico adequado.

> 💡 **A regra de ouro da visualização**
>
> O tipo de dado determina o tipo de gráfico. Antes de escolher *como* visualizar, pergunte: *que tipo de variável estou representando?* A resposta restringe automaticamente as opções válidas.

Uma variável numérica: distribuição

Quando temos **uma variável numérica** e queremos entender sua distribuição — onde se concentram os valores, se há assimetria, se existem outliers — os gráficos adequados são o **histograma** e o **boxplot**. Ambos exploram a natureza contínua (ou quase contínua) dos dados: a capacidade de ordenar valores e medir distâncias entre eles.

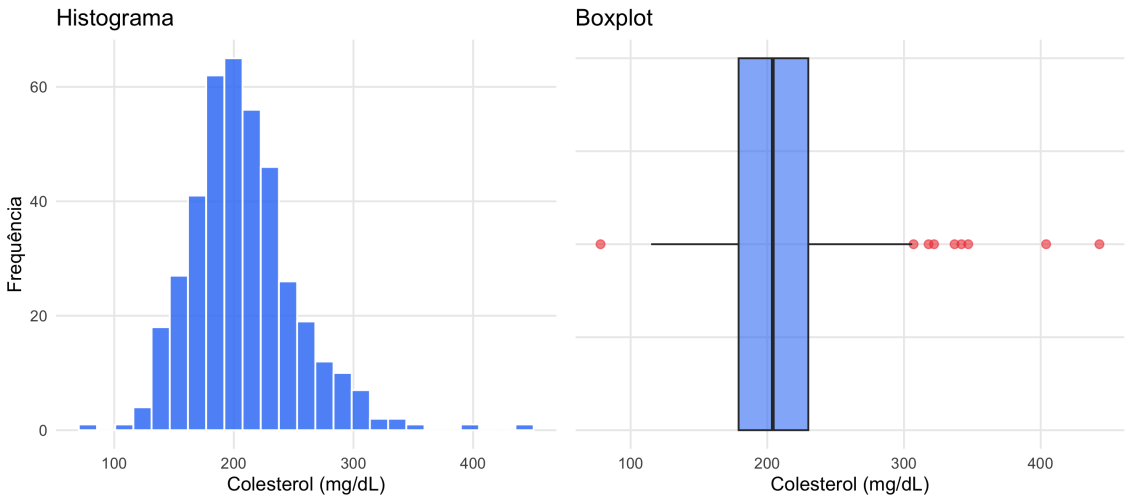

Figura 1: Duas formas de ver a mesma variável numérica (colesterol): o histograma revela a forma da distribuição; o boxplot resume os cinco números de Tukey.

O histograma é mais informativo — mostra bimodalidade, lacunas e a forma detalhada da curva. O boxplot é mais conciso — resume cinco números e sinaliza outliers. Na prática, o histograma é útil para **exploração** e o boxplot para **comparação entre grupos** (2).

> ⓘ **Histograma ≠ gráfico de barras**
>
> Embora visualmente parecidos, o histograma e o gráfico de barras são gráficos fundamentalmente diferentes. O histograma representa **intervalos contínuos** (as barras se tocam porque os valores são adjacentes); o gráfico de barras representa **categorias discretas** (as barras são separadas porque as categorias são distintas). Essa distinção reflete diretamente a diferença entre dados numéricos e categóricos.

Uma variável categórica: frequências

Para variáveis categóricas — nominais ou ordinais — o gráfico adequado é o **gráfico de barras**, que mostra a frequência (ou proporção) de cada categoria. O gráfico de barras respeita a natureza do dado: as categorias são posições discretas, e a altura da barra representa a contagem ou percentual.

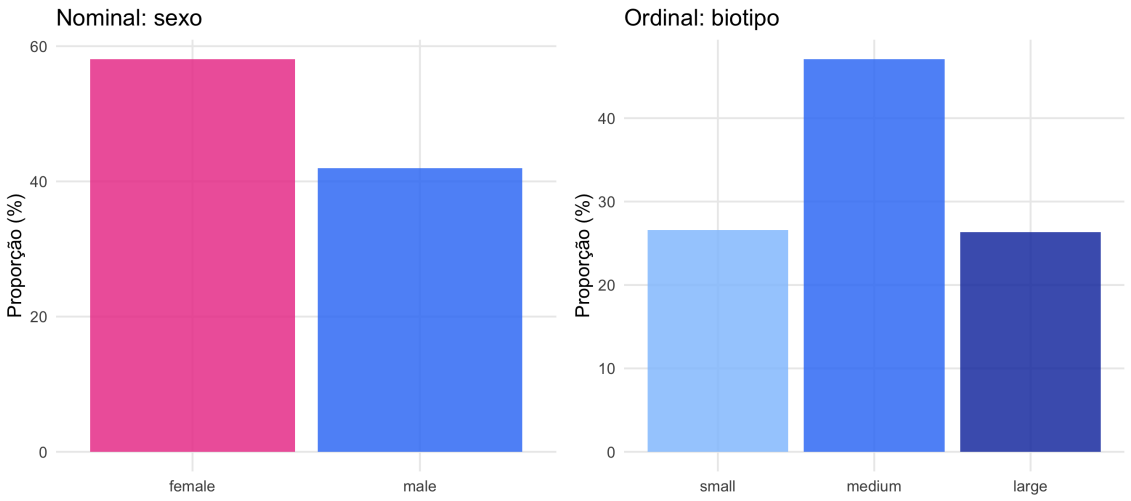

Figura 2: Gráficos de barras para variáveis nominais (sexo) e ordinais (biotipo) — note que a ordem das barras só importa para a ordinal.

Para variáveis **nominais**, a ordem das barras é arbitrária — podemos ordenar por frequência (maior para menor) para facilitar a leitura. Para variáveis **ordinais**, a ordem das barras **deve respeitar a hierarquia** dos níveis — small < medium < large — porque a posição no eixo carrega informação.

Numérica × categórica: comparação entre grupos

Uma das visualizações mais úteis em pesquisa em saúde é a comparação de uma variável numérica entre grupos definidos por uma variável categórica. O gráfico que faz isso de forma compacta e informativa é o **boxplot por grupo**.

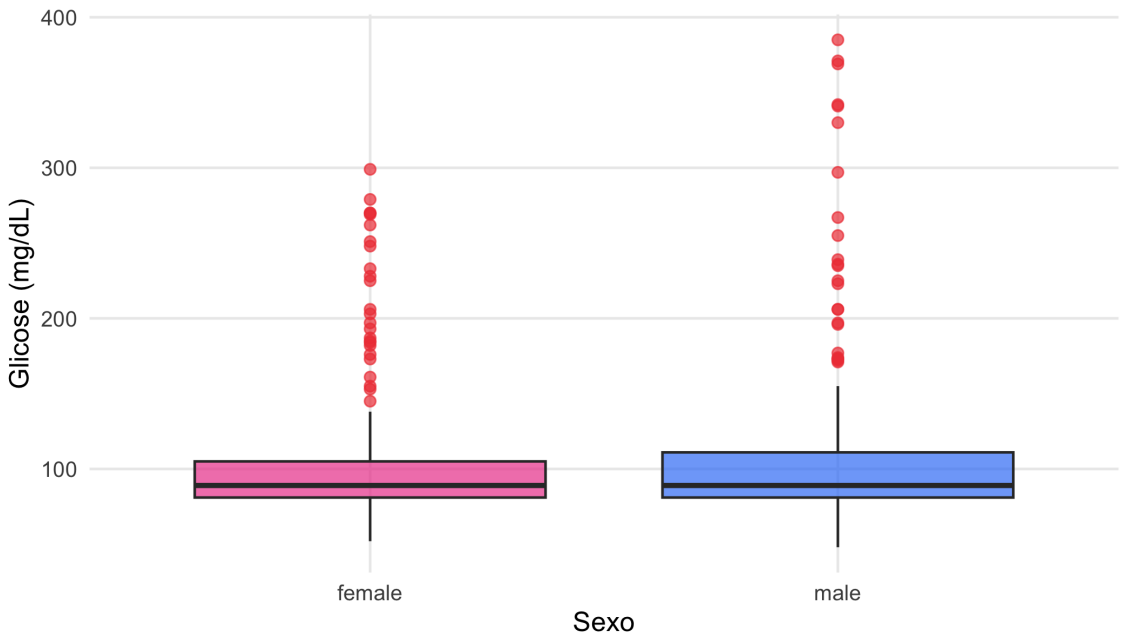

Figura 3: Comparação da glicose entre sexos — o boxplot permite comparar medianas, dispersão e outliers num único gráfico.

O boxplot por grupo combina informação de **duas variáveis** — uma numérica (glicose) e uma categórica (sexo) — permitindo comparar tendência central, dispersão e valores atípicos entre grupos. É o gráfico correspondente ao teste *t* ou Mann-Whitney, assim como o scatter plot é o gráfico correspondente à correlação.

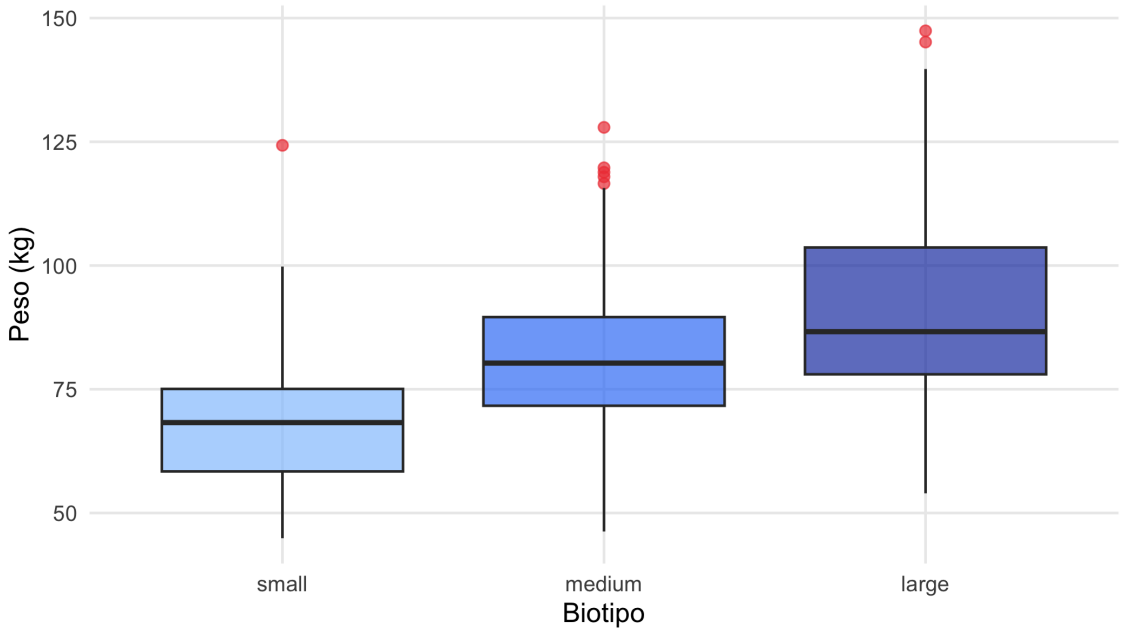

Figura 4: Peso por biotipo — a variável ordinal mantém sua ordem no eixo x.

Duas variáveis numéricas: relação

Quando temos **duas variáveis numéricas** e queremos avaliar se existe relação entre elas, o gráfico adequado é o **scatter plot** (diagrama de dispersão). Cada ponto representa um sujeito, posicionado segundo os valores das duas variáveis nos eixos x e y.

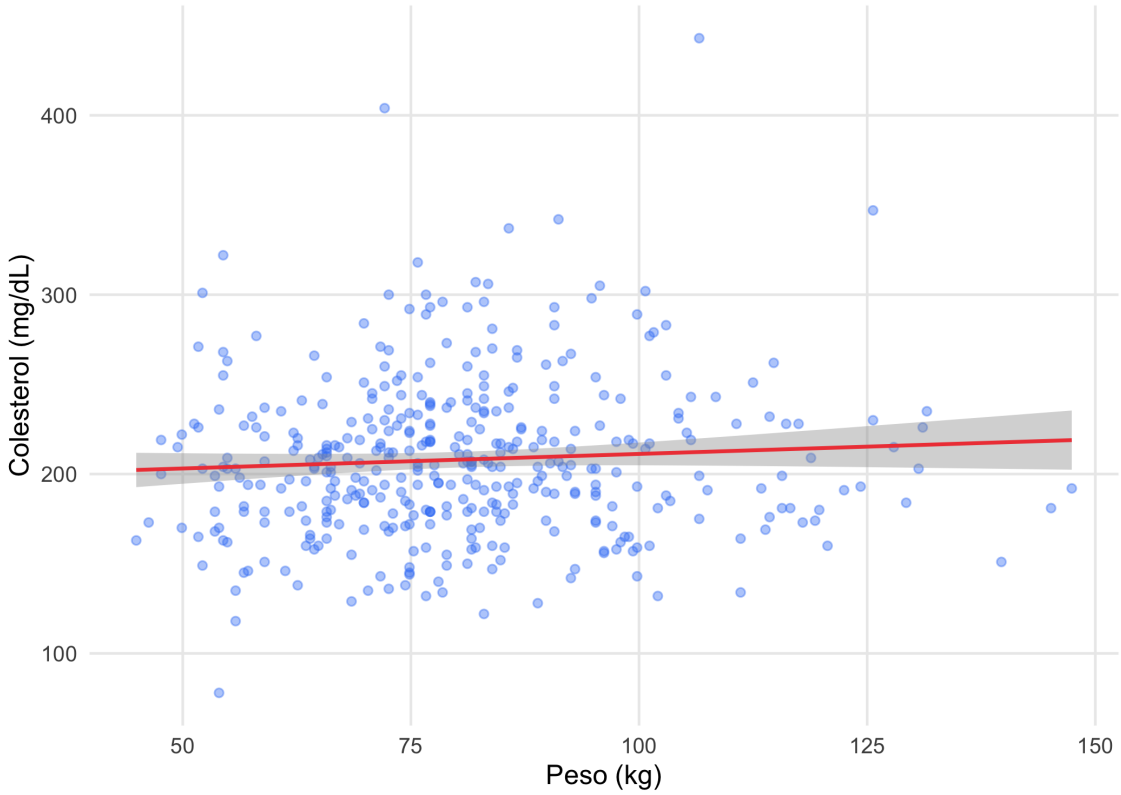

Figura 5: Relação entre peso e colesterol — cada ponto é um paciente. O scatter plot é o gráfico da correlação.

O scatter plot só faz sentido com duas variáveis numéricas — porque ambos os eixos precisam representar **magnitudes contínuas**. Para uma variável ordinal no eixo, o scatter plot perderia sua lógica visual; para uma nominal, não haveria como posicionar os pontos de forma significativa.

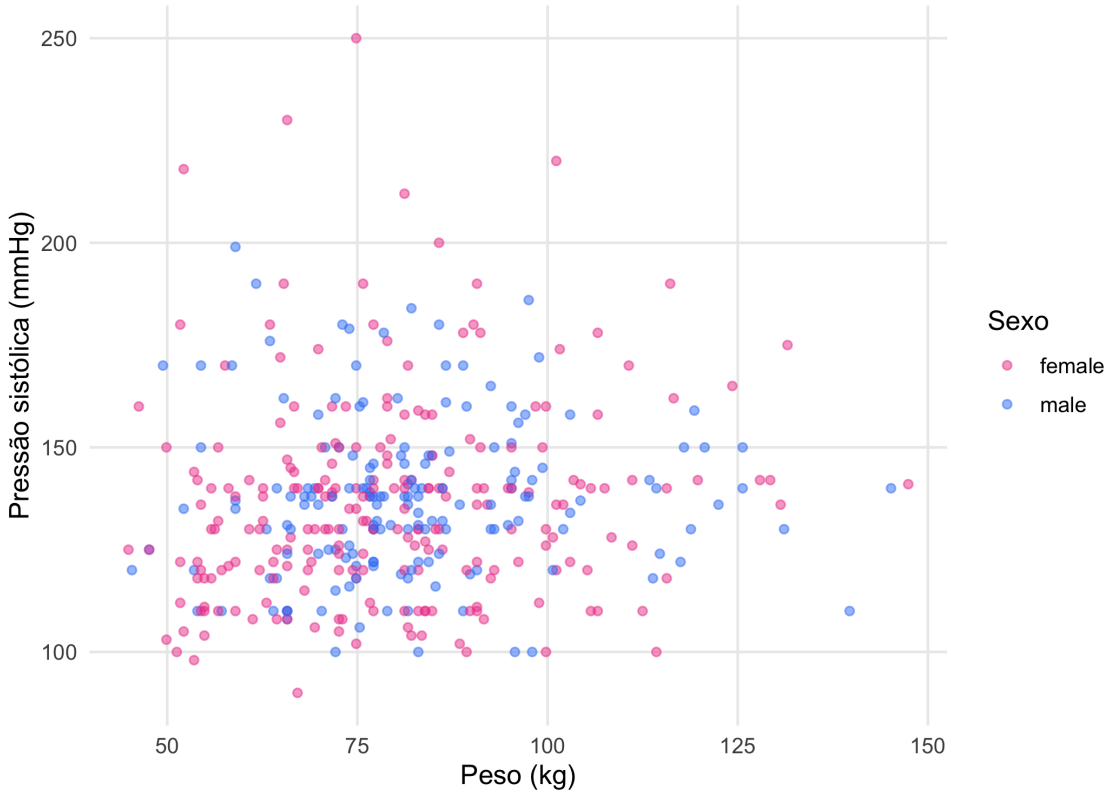

Figura 6: Scatter plot com destaque por sexo — adicionando uma terceira variável (categórica) por cor.

A cor pode codificar uma terceira variável — geralmente categórica — permitindo investigar se a relação entre as duas variáveis numéricas difere entre grupos.

Duas variáveis categóricas: associação

Para visualizar a **associação entre duas variáveis categóricas**, o gráfico de **barras empilhadas proporcionais** ou o **mosaico** são as opções adequadas. Eles representam visualmente a tabela de contingência que vimos no Capítulo 5.

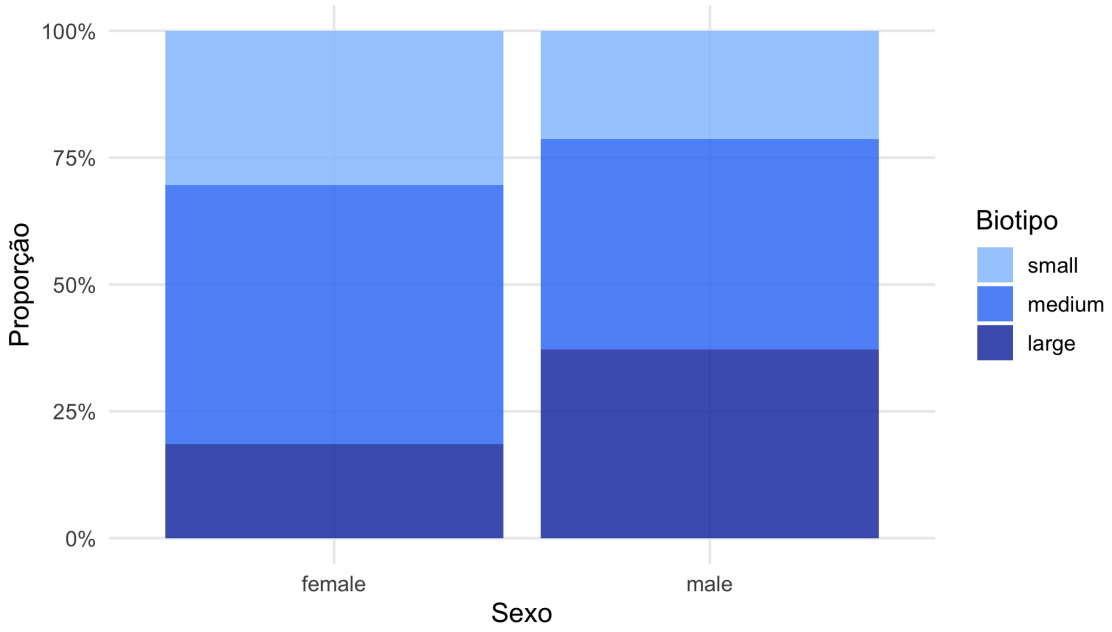

Figura 7: Distribuição do biotipo por sexo — barras empilhadas proporcionais permitem comparar perfis entre grupos.

O erro clássico: gráfico errado para o dado

Alguns erros de visualização resultam diretamente de ignorar o tipo de dado. São erros que nenhum ajuste estético resolve — porque o problema é estrutural.

Tabela 1: Erros clássicos de visualização — cada um viola a correspondência entre tipo de dado e tipo de gráfico.

Erro	Por que está errado	Alternativa correta
Histograma para dados categóricos	Categorias não têm adjacência — as barras não devem se tocar	Usar gráfico de barras (com espaço entre as barras)
Pizza para variável numérica	Proporções de faixas numéricas não somam um ‘todo’ natural	Usar barras para distribuição por faixas ou histograma para a variável contínua
Linha conectando categorias nominais	Linhas implicam continuidade entre pontos — categorias nominais são discretas	Usar barras; linhas só para dados temporais ou ordinais
		Reportar mediana ou mostrar frequências por nível

Erro	Por que está errado	Alternativa correta
Média em gráfico de dados ordinais	A linha da média pressupõe distâncias iguais entre níveis ordinais	
Scatter plot com variável categórica no eixo	Pontos empilhados numa mesma coordenada x não revelam distribuição	Usar boxplot por grupo ou gráficos de violino
Barras com eixo y que não começa em zero	Barras representam magnitude a partir de zero — truncar distorce proporções	Iniciar o eixo y em zero para barras; para linhas, a regra é mais flexível

O teste rápido

Antes de criar um gráfico, faça duas perguntas: (1) *Quantas variáveis estou representando?* e (2) *De que tipo são?* As respostas restringem automaticamente as opções válidas — e eliminam os erros mais comuns.

Guia rápido: tipo de dado → gráfico

A tabela a seguir resume a correspondência central deste capítulo. Para cada combinação de variáveis, há gráficos **recomendados** e gráficos **inadequados**.

Tabela 2: Guia rápido — qual gráfico usar para cada tipo de variável. Para detalhes sobre cada gráfico, consulte o site Dos Dados aos Gráficos.

Situação	Objetivo	Gráfico recomendado	Evitar
1 variável numérica contínua	Ver a distribuição	Histograma, densidade, boxplot	Barras separadas, pizza
1 variável numérica discreta	Ver a frequência de valores	Gráfico de barras (contagem), dot plot	Histograma com bins não inteiros
1 variável categórica nominal	Comparar proporções entre categorias	Gráfico de barras	Histograma, linha conectando categorias

Situação	Objetivo	Gráfico recomendado	Evitar
1 variável categórica ordinal	Comparar proporções respeitando a ordem	Gráfico de barras (ordem fixa dos níveis)	Pizza (perde a noção de ordem)
2 variáveis numéricas	Avaliar relação entre elas	Scatter plot (± linha de tendência)	Barras agrupadas com médias
Numérica × categórica	Comparar a numérica entre grupos	Boxplot por grupo, violin plot	Barras de médias sem dispersão
2 variáveis categóricas	Avaliar associação	Barras empilhadas, mosaico	Scatter plot, linhas
Variável ao longo do tempo	Mostrar tendência temporal	Gráfico de linhas	Barras (a menos que sejam intervalos discretos)

Para ir além

Este capítulo cobriu a lógica central: o tipo de dado determina o tipo de gráfico. Mas há muito mais a explorar — a gramática dos gráficos, os princípios de Tufte para design limpo e honesto, a galeria de erros clássicos e as ferramentas modernas (incluindo IA) para gerar visualizações em R.

Tudo isso está no site complementar Dos Dados aos Gráficos, que cobre:

Tabela 3: O que você encontra no site Dos Dados aos Gráficos — o complemento natural deste capítulo.

Parte	Conteúdo
I. Fundamentos	Quando usar um gráfico (vs. tabela), gramática dos gráficos (Wilkinson/Wickham), elementos de um gráfico, princípios de Tufte (data-ink ratio, chartjunk, lie factor)
II. Tipos de gráficos	Pizza, barras, histograma, densidade, boxplot, scatter plot, linhas e curvas de Kaplan-Meier — cada um com anatomia, quando usar, erros comuns e código R

Parte	Conteúdo
III. Pensamento crítico	Gráficos que mudaram a história (Nightingale, Snow, Challenger), mesmos dados com histórias diferentes, galeria de horrores com makeover
IV. Ferramentas	IA para gráficos (ChatGPT, Claude, Copilot), fluxograma interativo ‘Qual gráfico devo usar?’

Resumo do capítulo

Tabela 4: Resumo — a correspondência entre tipo de dado e tipo de gráfico.

Conceito	Definição	Exemplo do estudo
Tipo de dado → tipo de gráfico	A natureza da variável restringe automaticamente os gráficos válidos	Antes de escolher o gráfico, classifique a variável
Numérica contínua → histograma/ boxplot	Distribuição, forma, outliers — exploração de dados contínuos	Colesterol: histograma mostra assimetria; boxplot mostra outliers
Categórica → barras	Frequências e proporções — respeite a ordem se for ordinal	Sexo: barras (ordem livre); biotipo: barras (small < medium < large)
Numérica × categórica → boxplot por grupo	Comparação de distribuições entre grupos definidos por categorias	Glicose por sexo: boxplots lado a lado com outliers sinalizados
Duas numéricas → scatter plot	Relação entre magnitudes — cada ponto é uma observação	Peso × colesterol: scatter plot com linha de tendência
Duas categóricas → barras empilhadas	Associação entre categorias — versão visual da tabela de contingência	Sexo × biotipo: barras empilhadas proporcionais
Temporal → linhas	Tendência ao longo do tempo — linhas implicam continuidade temporal	Incidência de doença por mês/ ano: gráfico de linhas
Erro estrutural		

Conceito	Definição	Exemplo do estudo
	Usar o gráfico errado para o tipo de dado — nenhum ajuste estético resolve	Histograma para categorias, pizza para variável contínua, linha para nominal

> ⓘ **Próximos passos**
>
> Este capítulo mostrou que o tipo de dado determina o gráfico. No próximo e último capítulo, reuniremos tudo: como **reportar** dados corretamente em tabelas e texto de artigos científicos — integrando classificação, descrição e apresentação.

Referências

1. Cleveland WS, McGill R. Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods. Journal of the American Statistical Association. 1984;79(387):531–54.
2. Healy K. Data Visualization: A Practical Introduction. Princeton University Press; 2018.

Publicando seus Dados

Dados abertos, princípios FAIR e a crise de reprodutibilidade

A história

Em 2005, um epidemiologista grego radicado nos Estados Unidos publicou um artigo com um título provocativo: *Why Most Published Research Findings Are False*. O artigo, publicado na *PLOS Medicine*, tornou-se o mais acessado da história da revista — e um dos mais citados da ciência moderna. A tese era perturbadora: combinando vieses de publicação, tamanhos amostrais pequenos, flexibilidade na análise e pressão por resultados positivos, a maioria dos achados publicados em periódicos científicos era provavelmente **falsa** (1).

O argumento não era retórico — era matemático. Usando modelos bayesianos simples, o artigo demonstrava que, em cenários comuns de pesquisa (estudos pequenos, muitas variáveis testadas, poucos achados verdadeiros), a probabilidade de um resultado "significativo" ser verdadeiro era inferior a 50%. O problema não estava nos pesquisadores — estava no **sistema**: incentivos que premiavam descobertas e puniam replicações, periódicos que publicavam novidades e rejeitavam confirmações, e uma cultura que tratava dados como propriedade privada em vez de bem público.

Dez anos depois, a previsão se confirmou empiricamente. Em 2015, o Open Science Collaboration tentou replicar 100 estudos publicados em três importantes periódicos de psicologia. O resultado: apenas **36%** dos estudos originais produziram resultados significativos quando replicados. Os tamanhos de efeito médios caíram pela metade. A crise de reprodutibilidade não era mais uma hipótese — era um fato documentado (2).

A resposta da comunidade científica veio em múltiplas frentes: pré-registro de estudos, análises estatísticas mais rigorosas, combate ao *p-hacking*. Mas uma das respostas mais fundamentais foi

surpreendentemente simples: **tornar os dados disponíveis**. Se os dados por trás de uma publicação forem acessíveis, qualquer pesquisador pode verificar os resultados, reaplicar as análises e detectar erros — exatamente como Thomas Herndon fez com a planilha de Reinhart e Rogoff.

> **A lição de Ioannidis**
>
> A transparência é o antídoto para a irreplicabilidade. Quando os dados são abertos, os erros são corrigíveis, os resultados são verificáveis e a ciência avança — mesmo quando os achados originais estavam errados.

Por que publicar dados?

A publicação de dados — ou *data sharing* — não é apenas uma questão ética. É cada vez mais uma **exigência** dos principais periódicos e agências de fomento.

Tabela 1: Por que publicar dados — razões científicas, éticas e práticas.

Razão	Descrição
Reprodutibilidade	Outros pesquisadores podem reaplicar suas análises e confirmar (ou corrigir) seus resultados
Verificação	Erros como o de Reinhart-Rogoff podem ser identificados e corrigidos — a ciência se autocorrige
Reutilização	Seus dados podem ser combinados com outros em meta-análises ou usados para responder perguntas que você não fez
Exigência editorial	Periódicos como PLOS ONE, Nature, BMJ e The Lancet exigem ou incentivam dados abertos como condição de publicação
Citação	Dados publicados em repositórios recebem DOI e podem ser citados como uma publicação independente
Transparência ética	Pesquisa financiada com dinheiro público gera dados que pertencem à sociedade — não ao pesquisador

Princípios FAIR

Em 2016, um consórcio internacional de pesquisadores, agências de fomento e editores científicos propôs um conjunto de princípios para orientar a gestão de dados científicos. Chamados de **FAIR**, os princípios estabelecem que dados devem ser **F**indable (encontráveis), **A**ccessible (acessíveis), **I**nteroperable (interoperáveis) e **R**eusable (reutilizáveis) (3).

Tabela 2: Os princípios FAIR — o que cada letra significa na prática.

Princípio	Significado	Como implementar	No nosso banco
F — Findable (Encontrável)	Os dados podem ser encontrados por humanos e máquinas	Identificador persistente (DOI), metadados ricos e indexados em repositórios	Publicar em repositório com DOI (ex: Zenodo)
A — Accessible (Acessível)	Os dados podem ser obtidos por quem precisa deles	Protocolo aberto (HTTP), metadados sempre acessíveis — mesmo que os dados tenham restrições de acesso	Formato CSV aberto, sem autenticação para download
I — Interoperable (Interoperável)	Os dados podem ser combinados com outros dados	Formato aberto (CSV, não .xlsx proprietário), vocabulário padronizado, unidades explícitas	Nomes de variáveis em inglês, unidades no dicionário, formato UTF-8
R — Reusable (Reutilizável)	Os dados podem ser usados em novas análises	Licença clara (ex: CC-BY), documentação completa — incluindo o dicionário de variáveis	Dicionário completo (Cap. 7), licença definida, metodologia documentada

Note que FAIR **não significa acesso irrestrito**. Dados de pacientes, por exemplo, podem exigir anonimização ou acesso controlado. O princípio “Accessible” diz que os *metadados* devem ser sempre acessíveis — mesmo que os dados em si exijam autorização. A transparência está na **documentação**, não necessariamente no acesso livre (3).

Repositórios de dados

Onde publicar? Os dados não devem ficar apenas como “material suplementar” no site do periódico (que pode mudar de URL ou desaparecer). Devem ser depositados em **repositórios** que garantam persistência, DOI e indexação.

Tabela 3: Principais repositórios para publicação de dados científicos.

Repositório	Mantenedor	Custo	DOI	Destaque
Zenodo	CERN (Genebra)	Gratuito	Sim (automático)	Integração com GitHub; versões; comunidades temáticas
Figshare	Digital Science	Gratuito (até 5 GB)	Sim (automático)	Visualização online de dados e figuras; métricas de uso
Dryad	Dryad Digital Repository	Cobrado por alguns periódicos	Sim	Curadoria: os dados são revisados antes de publicar
OSF	Center for Open Science	Gratuito	Sim	Projetos completos: dados + código + pré-registro + artigo
Repositórios institucionais	Universidades	Varia	Varia	Exigência de algumas universidades para teses e dissertações

A escolha do repositório importa

Antes de publicar, verifique: (1) o periódico tem repositório preferencial? (2) sua universidade exige depósito institucional? (3) os dados contêm informação identificável que exija acesso controlado? A resposta a essas perguntas determina qual repositório é mais adequado.

O que publicar junto com os dados

Dados sem contexto são inúteis. Um arquivo CSV sem explicação é tão opaco quanto um artigo sem metodologia. Para que os dados sejam

reutilizáveis (o R de FAIR), é preciso acompanhá-los de documentação mínima:

Tabela 4: O pacote mínimo para publicação de dados — o que acompanha o CSV.

Componente	Descrição	Formato sugerido
Arquivo de dados	O banco de dados em formato aberto (CSV, UTF-8), com nomes de variáveis padronizados	.csv (UTF-8, vírgula como separador)
Dicionário de variáveis	Documento descrevendo cada variável: nome, tipo, unidade, valores possíveis, regras de codificação (como no Cap. 7)	.csv ou .md ou .pdf
README	Arquivo de texto descrevendo o estudo, a coleta, o período, os critérios de inclusão/exclusão e a versão dos dados	README.md ou README.txt
Script de análise	Código (R, Python) que reproduz as análises do artigo a partir dos dados brutos — o oposto de fórmulas escondidas no Excel	.R, .py, .qmd
Licença	Licença que especifica como os dados podem ser usados (ex: CC-BY 4.0 — uso livre com atribuição)	LICENSE.md ou campo no repositório

O dicionário como ato de transparência

O dicionário de variáveis — que construímos no Capítulo 7 — não é apenas uma boa prática de organização. Ele é o componente que transforma dados **acessíveis** em dados **reutilizáveis**. Sem o dicionário, um pesquisador que baixe seu CSV verá colunas como `glicohemoglobina`, `ratio` e `time.ppn` sem saber o que significam, em que unidade foram medidas ou qual a faixa de valores esperada (3).

O dicionário é para os dados o que a seção de Métodos é para o artigo: o elemento que permite a **reprodução**. As diretrizes STROBE para estudos observacionais recomendam explicitamente que os autores descrevam como cada variável foi definida e medida (4).

Tabela 5: Exemplo de dicionário publicável — cada variável documentada para reutilização.

Variável	Tipo de dado	Unidade	Valores	Ausentes	Observação
id	Identificador	—	1000–1402	Nenhum	Identificador único, não usar em análises
idade	Numérica contínua	anos completos	19–92	Nenhum	Calculada na data de inclusão; ver Cap. 4 sobre idade contínua vs. discreta
sexo	Categórica nominal (binária)	—	female, male	Nenhum	Sexo biológico declarado
colesterol	Numérica contínua	mg/dL	78–443	Codificados como NA	Colesterol total em jejum; dosagem laboratorial
glicose	Numérica contínua	mg/dL	48–385	Codificados como NA	Glicemia em jejum; dosagem laboratorial
biotipo	Categórica ordinal	—	small < medium < large	Codificados como NA	Classificação antropométrica: small, medium, large
sistolica	Numérica contínua	mmHg	82–250	Codificados como NA	Pressão arterial sistólica; esfigmomanômetro calibrado

Note como o tipo de dado — tema central de todo este projeto — aparece no dicionário como informação essencial. Saber que `biotipo` é ordinal (e não nominal) muda a análise: permite frequência acumulada, mediana e testes não paramétricos de tendência. Saber que `colesterol` é contínua de razão permite média, DP e teste *t*. O tipo de dado **não é óbvio** pelo nome da variável — precisa ser documentado.

O ciclo completo: do dado ao artigo, do artigo ao dado

Os nove capítulos deste projeto seguiram um percurso:

Tabela 6: O percurso completo — de Nightingale à publicação aberta.

Capítulo	Tema	Pergunta central	Narrativa histórica
Cap. 1	Dados e pesquisa	O que é um dado? O que é uma variável?	Florence Nightingale (1854)
Cap. 2	Classificação de variáveis	Como classificar variáveis? (Stevens, NOIR)	S. S. Stevens (1946)
Cap. 3	Dicionário de dados	Como documentar o banco de dados?	—
Cap. 4	Dados numéricos	Como descrever variáveis numéricas?	Quetelet (1835) + Tukey (1977)
Cap. 5	Dados categóricos	Como descrever variáveis categóricas?	John Graunt (1662)
Cap. 6	Casos especiais	O que fazer quando a classificação não é clara?	Rensis Likert (1932)
Cap. 7	Organização em planilhas	Como organizar dados para que sejam analisáveis?	Reinhart-Rogoff (2010/2013)
Cap. 8	Visualização por tipo	Qual gráfico para qual tipo de dado?	—
Cap. 9	Publicação e dados abertos	Como tornar os dados disponíveis para a comunidade?	Ioannidis (2005) + OSC (2015)

O fio condutor é o **tipo de dado**: como classificá-lo, como descrevê-lo, como visualizá-lo e, finalmente, como documentá-lo para que outros possam fazer o mesmo. A publicação de dados abertos — com dicionário, licença e código reproduzível — é o último passo desse ciclo, mas também o primeiro de um novo: o ciclo em que outros pesquisadores usam seus dados para fazer ciência que você não imaginou.

⚠ **O paradoxo de Ioannidis**

Se a maioria dos achados publicados é provavelmente falsa, a solução **não é** publicar menos — é publicar **melhor**. Dados abertos, análises reproduzíveis e documentação transparente não eliminam o erro, mas o tornam **detectável e corrigível**. A ciência não avança por ser perfeita — avança por ser autocorrigível.

Resumo do capítulo

Tabela 7: Resumo — publicação de dados e ciência aberta.

Conceito	Definição	Ação prática
Crise de reprodutibilidade	Muitos resultados publicados não se replicam — dados abertos são parte da solução	Tornar dados disponíveis para verificação e replicação
Princípios FAIR	Findable, Accessible, Interoperable, Reusable — o padrão internacional para dados científicos	Seguir os quatro princípios ao preparar dados para publicação
Repositórios de dados	Zenodo, Figshare, Dryad, OSF — garantem DOI, persistência e indexação	Depositar dados em repositório com DOI antes de submeter o artigo
Dicionário de variáveis	O documento que transforma um CSV opaco em dados reutilizáveis	Incluir tipo de dado, unidade, valores possíveis e regras de codificação
Pacote mínimo de publicação	Dados (CSV) + dicionário + README + script de análise + licença	Preparar todos os componentes antes da submissão ao periódico
Tipo de dado no dicionário	Especificar se a variável é numérica/categórica, discreta/contínua, nominal/ordinal — informação essencial para reutilização	Documentar o tipo de dado para cada variável — o tema central deste projeto

Fechando o ciclo

Este capítulo encerra o projeto — mas o tema não se encerra aqui. Cada artigo que você publicar, cada banco de dados que compartilhar, cada tabela descritiva que montar, começará pela mesma pergunta: **que tipo de dado é este?** A

resposta a essa pergunta determina como descrever, como visualizar, como analisar e como documentar. É o primeiro passo — e o mais importante.

Referências

1. Ioannidis JPA. Why Most Published Research Findings Are False. PLOS Medicine. 2005;2(8):e124.
2. Open Science Collaboration. Estimating the Reproducibility of Psychological Science. Science. 2015;349(6251):aac4716.
3. Wilkinson MD, Dumontier M, Aalbersberg IjJ, Appleton G, Axton M, Baak A, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship. Scientific Data. 2016;3:160018.
4. von Elm E, Altman DG, Egger M, Pocock SJ, Gøtzsche PC, Vandenbroucke JP. The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) Statement: Guidelines for Reporting Observational Studies. The Lancet. 2007;370(9596):1453–7.

Tipos de Dados no R e no Python

Da classificação conceitual à implementação no software

Introdução

Nos capítulos anteriores, aprendemos a classificar variáveis: numéricas ou categóricas, discretas ou contínuas, nominais ou ordinais. Essa classificação guia a escolha de estatísticas descritivas, gráficos e testes. Mas entre a classificação no papel e a análise no computador é preciso **dizer ao software o que cada variável representa**.

O problema é que R e Python não leem o dicionário de variáveis. Quando você importa uma planilha, o software faz sua própria classificação — e nem sempre acerta. Uma variável categórica codificada como 1, 2 e 3 será tratada como numérica. Uma variável numérica com vírgula decimal pode ser importada como texto. E o software não reclama: ele segue em frente, calcula o que você pedir e entrega um resultado — silenciosamente errado.

Este capítulo ensina a verificar e corrigir essa tradução. Vamos usar o nosso banco de dados `pacientes.csv` e mostrar, lado a lado, como R e Python lidam com cada tipo de dado.

O que o software vê quando você importa dados

Antes de classificar variáveis, vale entender o que acontece nos bastidores. Quando R ou Python importam um arquivo CSV, cada coluna recebe automaticamente um **tipo de dado** (*data type*) com base nos valores que encontra.

```
str(pacientes)
```

```
spc_tbl_ [403 × 18] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ n               : num [1:403] 1 2 3 4 5 6 7 8 9 10 ...
 $ id              : num [1:403] 1000 1001 1002 1003 1005 ...
 $ colesterol      : num [1:403] 203 165 228 78 249 248 195
227 177 263 ...
 $ glicose         : num [1:403] 82 97 92 93 90 94 92 75 87
89 ...
 $ hdl             : num [1:403] 56 24 37 12 28 69 41 44 49
40 ...
 $ ratio           : num [1:403] 3.6 6.9 6.2 6.5 8.9 ...
 $ glicohemoglobina: num [1:403] 4.31 4.44 4.64 4.63 7.72 ...
 $ cidade          : chr [1:403] "Buckingham" "Buckingham"
"Buckingham" "Buckingham" ...
 $ idade           : num [1:403] 46 29 58 67 64 34 30 37 45
55 ...
 $ sexo            : chr [1:403] "female" "female" "female"
"male" ...
 $ altura          : num [1:403] 157 163 155 170 173 ...
 $ peso            : num [1:403] 54.9 98.9 116.1 54 83 ...
 $ biotipo         : chr [1:403] "medium" "large" "large"
"large" ...
 $ sistolica       : num [1:403] 118 112 190 110 138 132 161
NA 160 108 ...
 $ diastolica      : num [1:403] 59 68 92 50 80 86 112 NA 80
72 ...
 $ cintura         : num [1:403] 29 46 49 33 44 36 46 34 34
45 ...
 $ quadril         : num [1:403] 38 48 57 38 41 42 49 39 40
50 ...
 $ time.ppn        : num [1:403] 720 360 180 480 300 195 720
1020 300 240 ...
 - attr(*, "spec")=
  .. cols(
  ..   n = col_double(),
  ..   id = col_double(),
  ..   colesterol = col_double(),
  ..   glicose = col_double(),
  ..   hdl = col_double(),
  ..   ratio = col_double(),
  ..   glicohemoglobina = col_double(),
  ..   cidade = col_character(),
  ..   idade = col_double(),
  ..   sexo = col_character(),
  ..   altura = col_double(),
  ..   peso = col_double(),
  ..   biotipo = col_character(),
  ..   sistolica = col_double(),
```

```
  ..   diastolica = col_double(),
  ..   cintura = col_double(),
  ..   quadril = col_double(),
  ..   time.ppn = col_double()
  .. )
 - attr(*, "problems")=<externalptr>
```

No R, `str()` mostra a estrutura do data frame. Cada coluna tem um tipo: `num` (numérico), `chr` (texto), `int` (inteiro). Note que `sexo`, `cidade` e `biotipo` foram importadas como `chr` — o R não sabe que são categóricas.

A mensagem é a mesma nos dois ambientes: **a importação automática não é suficiente**. O software adivinha tipos com base nos valores, não no significado das variáveis. Cabe ao pesquisador corrigir.

Variáveis numéricas

Variáveis numéricas são as mais simples de lidar — na maioria dos casos, a importação automática acerta. Peso, colesterol, glicose e pressão arterial entram como números decimais; idade, como inteiro.

```r
class(pacientes$peso)       # "numeric" (decimal)
```

```
[1] "numeric"
```

```r
class(pacientes$idade)      # "numeric" (importado como decimal, mesmo sendo inte
```

```
[1] "numeric"
```

```r
is.numeric(pacientes$peso)  # TRUE
```

```
[1] TRUE
```

No R, tanto `integer` quanto `numeric` (que internamente é `double`) são tratados como numéricos. Na prática, essa diferença raramente importa: o R converte automaticamente entre os dois quando necessário. O importante é que `is.numeric()` retorne `TRUE`.

Para forçar uma variável a ser inteira (por exemplo, contagens):

```
pacientes$idade_int <- as.integer(pacientes$idade)
class(pacientes$idade_int)
```

```
[1] "integer"
```

Quando inteiro vs. decimal importa?

Na grande maioria das análises em saúde, não importa. Média, desvio-padrão, teste *t* e regressão linear funcionam da mesma forma para ambos. A exceção são modelos de contagem (Poisson, binomial negativa), que esperam valores inteiros. Fora isso, não perca tempo convertendo tipos numéricos entre si.

Variáveis categóricas nominais

Aqui começa a parte que exige atenção do pesquisador. Quando o R ou o Python importam uma coluna com valores como “female” e “male”, eles a armazenam como texto — não como uma variável categórica com níveis definidos. Isso significa que o software não sabe quantas categorias existem, não sabe ordená-las, e não sabe que “Female” e “female” deveriam ser a mesma coisa.

```
# Antes da conversão: texto puro
class(pacientes$sexo)
```

```
[1] "character"
```

```
# Converter para fator
pacientes$sexo <- factor(pacientes$sexo)
class(pacientes$sexo)
```

```
[1] "factor"
```

```r
levels(pacientes$sexo)
```

```
[1] "female" "male"
```

O `factor` é o tipo do R para variáveis categóricas. Ao converter, o R identifica automaticamente os níveis únicos. Você pode definir os níveis explicitamente — útil para controlar a ordem em gráficos e tabelas:

```r
pacientes$sexo <- factor(pacientes$sexo,
                         levels = c("female", "male"),
                         labels = c("Feminino", "Masculino"))
levels(pacientes$sexo)
```

```
[1] "Feminino"  "Masculino"
```

```r
table(pacientes$sexo)
```

```

  Feminino Masculino
       234       169
```

Cuidado: se você define `levels` que não existem nos dados, as observações correspondentes viram `NA`. Se um valor nos dados não está na lista de `levels`, ele também vira `NA`. Isso é uma proteção, mas pode ser uma armadilha se houver erros de digitação.

Variáveis categóricas ordinais

Variáveis ordinais exigem um passo a mais: além de dizer ao software que são categóricas, precisamos informar a **ordem** dos níveis. Sem isso, o software trata “small”, “medium” e “large” como categorias sem

hierarquia — e gráficos, tabelas e testes podem apresentar os níveis em ordem alfabética ou aleatória.

```r
# Criar fator ordenado
pacientes$biotipo <- factor(pacientes$biotipo,
                            levels = c("small", "medium", "large"),
                            ordered = TRUE)
class(pacientes$biotipo)
```

```
[1] "ordered" "factor"
```

```r
levels(pacientes$biotipo)
```

```
[1] "small"  "medium" "large"
```

```r
# Agora o R sabe que small < medium < large
pacientes$biotipo[1] < pacientes$biotipo[2]
```

```
[1] TRUE
```

A diferença entre `factor` e `ordered factor` é sutil mas importante: com um fator ordenado, operações de comparação (`<`, `>`) funcionam, e algumas funções estatísticas (como `polr()` para regressão ordinal) reconhecem automaticamente a ordem.

⚠ **Ordem errada é pior que nenhuma ordem**

Definir a ordem errada dos níveis (por exemplo, `large < medium < small`) não gera erro — o software aceita silenciosamente. Mas todas as análises que dependem da ordem (medianas, testes ordinais, gráficos) estarão invertidas. Sempre verifique com `levels()` no R ou `.cat.categories` no Python após definir a ordem.

Variáveis binárias

Como vimos no Capítulo 2, variáveis binárias vivem na fronteira entre o categórico e o numérico. No software, essa dupla natureza se traduz em uma escolha prática: armazenar como fator de dois níveis ou como 0/1 numérico?

```r
# Opção 1: como fator (categórica)
obito <- factor(c("sim", "não", "sim", "não", "sim"),
                levels = c("não", "sim"))
table(obito)
```

```
obito
não sim
  2   3
```

```r
# Opção 2: como numérico 0/1
obito_num <- as.numeric(obito) - 1  # factor começa em 1, então subtrai 1
mean(obito_num)  # proporção de óbitos
```

```
[1] 0.6
```

```r
# Opção 3: como lógico
obito_log <- c(TRUE, FALSE, TRUE, FALSE, TRUE)
mean(obito_log)  # R converte TRUE=1, FALSE=0 automaticamente
```

```
[1] 0.6
```

No R, `factor` é a escolha padrão para análises descritivas e tabelas de contingência. Mas funções como `glm()` (regressão logística) aceitam tanto `factor` quanto `0/1` — e muitos usuários preferem a codificação numérica pela transparência: fica claro qual categoria é 0 e qual é 1.

A regra prática: se a variável vai entrar em um modelo estatístico, verifique o que a função espera. Se vai aparecer em uma tabela ou

gráfico descritivo, `factor`/`category` com rótulos legíveis é a melhor escolha.

Armadilhas comuns na importação

A importação automática funciona bem na maioria dos casos — mas quando falha, falha silenciosamente. Aqui estão os problemas mais frequentes.

O número que virou texto

O separador decimal no Brasil é a vírgula (72,5 kg), mas o padrão internacional é o ponto (72.5). Se o CSV usa vírgula e o software espera ponto, a coluna inteira é importada como texto.

```
# Simulando o problema
peso_texto <- c("72,5", "68,3", "81,0")
class(peso_texto)  # "character"
```

```
[1] "character"
```

```
# mean(peso_texto)  # ERRO: argumento não é numérico

# Solução 1: converter manualmente
peso_num <- as.numeric(gsub(",", ".", peso_texto))
peso_num
```

```
[1] 72.5 68.3 81.0
```

```
# Solução 2: usar read_csv2() do readr, que espera ; como separador
# e , como decimal (padrão europeu/brasileiro)
# pacientes <- read_csv2("data/pacientes.csv")
```

A categórica disfarçada de número

Códigos numéricos para categorias (1 = leve, 2 = moderado, 3 = grave) são importados como números — e o software não tem como saber que

representam categorias. A média de 2,3 “graus de gravidade” não tem sentido, mas o software a calcula sem hesitar.

```
# O problema: parece numérica, mas é categórica
gravidade_cod <- c(1, 2, 3, 2, 1, 3, 2)
mean(gravidade_cod)  # 2.0 — sem sentido clínico!
```

```
[1] 2
```

```
# A solução: converter para fator
gravidade <- factor(gravidade_cod,
                    levels = c(1, 2, 3),
                    labels = c("Leve", "Moderado", "Grave"),
                    ordered = TRUE)
gravidade
```

```
[1] Leve     Moderado Grave    Moderado Leve     Grave
Moderado
Levels: Leve < Moderado < Grave
```

```
# mean(gravidade)  # ERRO — agora o R protege contra o uso indevido
```

O NA invisível

Valores ausentes podem aparecer de muitas formas: célula vazia, “NA”, “N/A”, “.”, “-”, “999”, “não informado”. O R e o Python reconhecem alguns desses automaticamente, mas não todos.

```
# O R reconhece automaticamente: NA, "", "NA"
# Mas não reconhece: "999", ".", "-", "não informado"

# Solução na importação:
# pacientes <- read_csv("data/pacientes.csv", na = c("", "NA", "999", "."))

# Verificar missings após importação
colSums(is.na(pacientes[, c("colesterol", "glicose", "hdl", "peso")]))
```

```
colesterol    glicose        hdl       peso
         1          0          1          1
```

Um workflow de verificação

Após importar os dados, um workflow rápido de verificação evita surpresas na análise. São poucos comandos, mas podem salvar horas de trabalho.

```r
# 1. Estrutura geral
glimpse(pacientes)
```

```
Rows: 403
Columns: 19
$ n                <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11,
12, 13, 14, 15, 16…
$ id               <dbl> 1000, 1001, 1002, 1003, 1005, 1008,
1011, 1015, 1016,…
$ colesterol       <dbl> 203, 165, 228, 78, 249, 248, 195,
227, 177, 263, 242,…
$ glicose          <dbl> 82, 97, 92, 93, 90, 94, 92, 75, 87,
89, 82, 128, 75, …
$ hdl              <dbl> 56, 24, 37, 12, 28, 69, 41, 44, 49,
40, 54, 34, 36, 4…
$ ratio            <dbl> 3.6, 6.9, 6.2, 6.5, 8.9, 3.6, 4.8,
5.2, 3.6, 6.6, 4.5…
$ glicohemoglobina <dbl> 4.31, 4.44, 4.64, 4.63, 7.72, 4.81,
4.84, 3.94, 4.84,…
$ cidade           <chr> "Buckingham", "Buckingham",
"Buckingham", "Buckingham…
$ idade            <dbl> 46, 29, 58, 67, 64, 34, 30, 37, 45,
55, 60, 38, 27, 4…
$ sexo             <fct> Feminino, Feminino, Feminino,
Masculino, Masculino, M…
$ altura           <dbl> 157.48, 162.56, 154.94, 170.18,
172.72, 180.34, 175.2…
$ peso             <dbl> 54.88463, 98.88306, 116.11955,
53.97745, 83.00734, 86…
$ biotipo          <ord> medium, large, large, large, medium,
large, medium, m…
```

```
$ sistolica        <dbl> 118, 112, 190, 110, 138, 132, 161,
NA, 160, 108, 130,…
$ diastolica       <dbl> 59, 68, 92, 50, 80, 86, 112, NA, 80,
72, 90, 68, 80, …
$ cintura          <dbl> 29, 46, 49, 33, 44, 36, 46, 34, 34,
45, 39, 42, 35, 3…
$ quadril          <dbl> 38, 48, 57, 38, 41, 42, 49, 39, 40,
50, 45, 50, 41, 4…
$ time.ppn         <dbl> 720, 360, 180, 480, 300, 195, 720,
1020, 300, 240, 30…
$ idade_int        <int> 46, 29, 58, 67, 64, 34, 30, 37, 45,
55, 60, 38, 27, 4…
```

```r
# 2. Verificar se os tipos estão corretos
sapply(pacientes[, c("colesterol", "peso", "idade")], is.numeric)
```

```
colesterol       peso      idade
      TRUE       TRUE       TRUE
```

```r
sapply(pacientes[, c("sexo", "cidade", "biotipo")], is.factor)
```

```
   sexo  cidade biotipo
   TRUE   FALSE    TRUE
```

O workflow completo segue três passos:

1. **Olhar a estrutura** — `glimpse()` ou `.info()` revelam imediatamente se alguma variável está no tipo errado.
2. **Corrigir os tipos** — converter categóricas para `factor`/`category`, definir ordem para ordinais, tratar missings.
3. **Confirmar** — repetir o passo 1 para verificar que as correções foram aplicadas.

Faça isso uma vez, no início

A conversão de tipos deve ser feita **uma única vez**, logo após a importação, e de preferência em um script separado ou em um chunk de setup. Isso garante que todas as análises subsequentes partam de dados corretamente tipados — e evita

a situação em que um gráfico funciona mas um teste falha porque a variável estava como texto em vez de fator.

Tabela de correspondência

A tabela abaixo resume a correspondência entre a classificação estatística e os tipos de dados no R e no Python:

Tabela 1: Da classificação estatística ao código — correspondência entre tipos conceituais e tipos no software.

Classificação	Tipo no R	Tipo no Python	Como verificar (R)	Cuidado
Numérico contínuo	`numeric` / `double`	`float64`	`is.numeric()`	Inteiro importado como double
Numérico discreto	`integer`	`int64`	`is.integer()`	Pode ser categórica disfarçada
Categórico nominal	`factor`	`category`	`is.factor()`	Texto ≠ fator
Categórico ordinal	`ordered factor`	`CategoricalDtype(ordered=True)`	`is.ordered()`	Sem `ordered=TRUE` vira nominal
Binário (como categórica)	`factor` (2 níveis)	`category` (2 níveis)	`is.factor()` + `nlevels() == 2`	Definir nível de referência
Binário (como numérica)	`numeric` (0/1) ou `logical`	`int64` (0/1) ou `bool`	`is.numeric()` ou `is.logical()`	Saber qual é 0 e qual é 1

Resumo do capítulo

Tabela 2: Resumo — tipos de dados no R e no Python.

Conceito	Resumo
Importação automática	O software adivinha tipos, mas nem sempre acerta — verificação manual é obrigatória
Variáveis numéricas	Geralmente importadas corretamente; integer vs double raramente importa na prática
Variáveis categóricas nominais	Importadas como texto; converter para factor/category para que o software reconheça os níveis
Variáveis categóricas ordinais	Exigem definição explícita da ordem dos níveis; sem isso, são tratadas como nominais
Variáveis binárias	Podem ser armazenadas como fator ou como 0/1 — a escolha depende da análise
Armadilhas comuns	Vírgula vs ponto decimal, códigos numéricos para categorias, valores ausentes não reconhecidos
Workflow de verificação	Importar → verificar tipos (glimpse/info) → corrigir → confirmar

ⓘ **A ponte entre os capítulos**

Este capítulo fecha o ciclo que começou no Capítulo 2. Lá, aprendemos a classificar variáveis conceitualmente. Aqui, traduzimos essa classificação para a linguagem do software. Entre esses dois pontos — a classificação no papel e o tipo no código — está a maioria dos erros silenciosos que comprometem análises em saúde. A boa notícia: poucos minutos de verificação após a importação são suficientes para evitá-los.

Referências

1. Stevens SS. On the Theory of Scales of Measurement. Science. 1946;103(2684):677–80.
2. Velleman PF, Wilkinson L. Nominal, Ordinal, Interval, and Ratio Typologies Are Misleading. The American Statistician. 1993;47(1): 65–72.
3. Michell J. Measurement Scales and Statistics: A Clash of Paradigms. Psychological Bulletin. 1986;100(3):398–407.
4. Chrisman NR. Rethinking Levels of Measurement for Cartography. Cartography and Geographic Information Science. 1998;25(4):231–42.
5. Agresti A. Categorical Data Analysis. 3.ª ed. Hoboken, NJ: John Wiley & Sons; 2013.
6. Agresti A. Statistical Methods for the Social Sciences. 5.ª ed. Boston: Pearson; 2018.
7. Siegel S, Castellan Jr. NJ. Nonparametric Statistics for the Behavioral Sciences. 2.ª ed. New York: McGraw-Hill; 1988.
8. Hand DJ. Measurement Theory and Practice: The World Through Quantification. London: Arnold Publishers; 2004.
9. Tukey JW. Exploratory Data Analysis. Reading, MA: Addison-Wesley; 1977.
10. Likert R. A Technique for the Measurement of Attitudes. Archives of Psychology. 1932;22(140):5–55.
11. Carifio J, Perla R. Resolving the 50-Year Debate Around Using and Misusing Likert Scales. Medical Education. 2008;42(12):1150–2.
12. Norman G. Likert Scales, Levels of Measurement and the «Laws» of Statistics. Advances in Health Sciences Education. 2010;15(5): 625–32.
13. Jamieson S. Likert Scales: How to (Ab)use Them. Medical Education. 2004;38(12):1217–8.
14. Sullivan GM, Artino Jr. AR. Analyzing and Interpreting Data From Likert-Type Scales. Journal of Graduate Medical Education. 2013;5(4):541–2.

15. Elm E von, Altman DG, Egger M, Pocock SJ, Gøtzsche PC, Vandenbroucke JP. The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) Statement: Guidelines for Reporting Observational Studies. The Lancet. 2007;370(9596):1453–7.
16. Vandenbroucke JP, Elm E von, Altman DG, Gøtzsche PC, Mulrow CD, Pocock SJ, et al. Strengthening the Reporting of Observational Studies in Epidemiology (STROBE): Explanation and Elaboration. Annals of Internal Medicine. 2007;147(8):W-163-W-194.
17. Broman KW, Woo KH. Data Organization in Spreadsheets. The American Statistician. 2018;72(1):2–10.
18. Wickham H. Tidy Data. Journal of Statistical Software. 2014;59(10): 1–23.
19. Hesse R, Hesse Scerno D. How Electronic Spreadsheets Changed the World. Interfaces. 2009;39(2):159–67.
20. Reinhart CM, Rogoff KS. Growth in a Time of Debt. American Economic Review. 2010;100(2):573–8.
21. Herndon T, Ash M, Pollin R. Does High Public Debt Consistently Stifle Economic Growth? A Critique of Reinhart and Rogoff. Cambridge Journal of Economics. 2014;38(2):257–79.
22. Cleveland WS, McGill R. Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods. Journal of the American Statistical Association. 1984;79(387):531–54.
23. Few S. Show Me the Numbers: Designing Tables and Graphs to Enlighten. 2.ª ed. Burlingame, CA: Analytics Press; 2012.
24. Healy K. Data Visualization: A Practical Introduction. Princeton University Press; 2018.
25. Ioannidis JPA. Why Most Published Research Findings Are False. PLOS Medicine. 2005;2(8):e124.
26. Wilkinson MD, Dumontier M, Aalbersberg IjJ, Appleton G, Axton M, Baak A, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship. Scientific Data. 2016;3:160018.
27. Open Science Collaboration. Estimating the Reproducibility of Psychological Science. Science. 2015;349(6251):aac4716.
28.

Nightingale F. Notes on Hospitals. 3.ª ed. London: Longman, Green, Longman, Roberts,; Green; 1863.

29. Bradshaw NA. Florence Nightingale (1820–1910): An Unexpected Master of Data. Patterns. 2020;1(2):100036.
30. Graunt J. Natural and Political Observations Mentioned in a Following Index, and Made upon the Bills of Mortality. London: Tho. Roycroft for John Martin, James Allestry,; Tho. Dicas; 1662.
31. Quetelet A. Sur l'Homme et le Développement de ses Facultés, ou Essai de Physique Sociale. Paris: Bachelier; 1835.
32. Stigler SM. The History of Statistics: The Measurement of Uncertainty Before 1900. Cambridge, MA: Harvard University Press; 1986.
33. Stigler SM. Statistics on the Table: The History of Statistical Concepts and Methods. Cambridge, MA: Harvard University Press; 1999.
34. Desrosières A. The Politics of Large Numbers: A History of Statistical Reasoning. Cambridge, MA: Harvard University Press; 1998.
35. Mars Climate Orbiter Mishap Investigation Board. Mars Climate Orbiter Mishap Investigation Board Phase I Report [Internet]. NASA; 1999. Disponível em: https://llis.nasa.gov/llis_lib/pdf/1009464main1_0641-mr.pdf
36. Freedman DA, Pisani R, Purves RA. Statistics. 4.ª ed. New York: W. W. Norton & Company; 2007.
37. Altman DG. Practical Statistics for Medical Research. London: Chapman; Hall; 1991.
38. Pagano M, Gauvreau K. Principles of Biostatistics. 2.ª ed. Boca Raton, FL: Chapman; Hall/CRC; 2018.
39. Rosner B. Fundamentals of Biostatistics. 8.ª ed. Boston: Cengage Learning; 2015.
40. Dancey CP, Reidy J. Statistics Without Maths for Psychology. 7.ª ed. Harlow, UK: Pearson; 2017.

Sobre este projeto

Informações sobre o autor, tecnologias e licenciamento

Autor

Henrique Alvarenga da Silva

Médico psiquiatra. Professor de Psiquiatria e Psicopatologia no curso de Medicina da Universidade Federal de São João del-Rei (UFSJ). Professor de Métodos de Pesquisa em Medicina na UNIPTAN/AFYA.

henriquealvarenga.com

henriquealvarenga@ufsj.edu.br

ORCID: 0000-0001-9799-5240

Sobre a obra

Este material foi desenvolvido como recurso educacional para estudantes de medicina, residentes e profissionais da área da saúde que desejam compreender os fundamentos da classificação e organização de dados em pesquisa. O conteúdo abrange desde a definição de variáveis e escalas de medida até a publicação de dados segundo princípios de ciência aberta.

Tecnologias utilizadas

Este material foi produzido utilizando ferramentas de código aberto e ciência aberta:

Tecnologia	Finalidade
R	Linguagem de programação estatística

Tecnologia	Finalidade
Quarto	Sistema de publicação científica e técnica
Markdown	Linguagem de marcação para escrita do conteúdo
Positron	Ambiente de desenvolvimento integrado (IDE)
Git	Controle de versão
GitHub	Hospedagem do repositório e controle de versão
GitHub Pages	Publicação e hospedagem do site
BibTeX	Gerenciamento de referências bibliográficas

Inteligência artificial

O desenvolvimento deste material contou com o auxílio de ferramentas de inteligência artificial generativa:

- **Claude** (Anthropic) — assistência na estruturação do conteúdo, geração de código R, revisão textual e organização das referências
- **ChatGPT** (OpenAI) — apoio na elaboração de seções específicas e revisão de conteúdo

O uso dessas ferramentas seguiu princípios de transparência e verificação: todo o conteúdo gerado foi revisado, verificado e validado pelo autor. As referências bibliográficas foram conferidas individualmente para garantir precisão e veracidade.

> ⓘ **Nota sobre o uso de IA**
>
> A inteligência artificial foi utilizada como ferramenta de apoio, não como substituto do trabalho intelectual. A responsabilidade pelo conteúdo final, incluindo a precisão das informações, do código e a adequação das referências, é integralmente do autor.

Repositório

O código-fonte deste projeto está disponível publicamente:

 Repositório: github.com/henriquealvarenga/tiposdedados

Contribuições, sugestões e correções são bem-vindas por meio de *issues* ou *pull requests*.

Outros projetos do autor

- Dos Dados aos Gráficos — Visualização estatística para profissionais de saúde

Licença

Este trabalho está licenciado sob uma Licença **Creative Commons Atribuição-NãoComercial-CompartilhaIgual 4.0 Internacional (CC BY-NC-SA 4.0)**.

Você tem o direito de:

- **Compartilhar** — copiar e redistribuir o material em qualquer suporte ou formato
- **Adaptar** — remixar, transformar e criar a partir do material

Sob os seguintes termos:

- **Atribuição** — Você deve dar o crédito apropriado, fornecer um link para a licença e indicar se mudanças foram feitas
- **NãoComercial** — Você não pode usar o material para fins comerciais
- **CompartilhaIgual** — Se você remixar, transformar ou criar a partir do material, deve distribuir suas contribuições sob a mesma licença

Texto completo da licença

Citação

Selecione o formato desejado e clique em **Copiar** para copiar a citação:

```
SILVA, Henrique Alvarenga da. Tipos de Dados em Saúde: Da Coleta à Análise. Publicação independente, 2026. Disponível em: https://henriquealvarenga.com/tiposdedados/
```

ISBN

ISBN: (em tramitação)

Código ISBN e código de barras serão incluídos após registro.

Ficha catalográfica

Ficha Catalográfica

Ficha catalográfica será incluída após elaboração.

Agradecimentos

Agradeço aos estudantes e colegas que, ao longo dos anos, motivaram a criação deste material com suas dúvidas, sugestões e entusiasmo pela pesquisa científica e pela compreensão dos dados em saúde.

Histórico de versões

Versão	Data	Descrição
1.0.0	Março/2026	Versão inicial

Contato

Dúvidas, sugestões ou correções podem ser enviadas para:

henriquealvarenga@ufsj.edu.br

Ou por meio de *issues* no repositório do projeto no GitHub.

Última atualização: Março de 2026